Introducción al Análisis de Datos con R

Agustin Alesso Patricia Acetta

Tabla de contenidos

Bienvenidos!

¡Bienvenidos al curos de *Introducción al Análisis de Datos con R*!

Objetivos del curso

- Reconocer al lenguaje R, y su entorno de desarrollo RStudio, como herramienta para el procesamiento y análisis de datos.
- Identificar y explicar los tipos y estructuras de datos representados en R.
- Identificar y emplear funciones y librerías útiles para el procesamiento, visualización y análisis de datos en R.
- Aplicar técnicas estadísticas básicas para analizar datos en R.
- Crear visualizaciones efectivas para comunicar resultados.
- Aplicar los principios de reproducibilidad para procesar y analizar datos y comunicar resultados

Contenidos

- **Unidad 1**: ¿Qué es R y RStudio? Instalación de R y RStudio. Características RStudio: menús, paneles, etc. Sintaxis de R, convenciones y símbolos de R. Sistema de librerías: instalación y carga. Sistema de ayuda. Tipos de datos: numérico, caracter, lógico. Funciones. Estructuras de datos: vectores, listas, hoja de datos (data frame). El flujo de trabajo en un proyecto de análisis de datos: proyectos, scripts y notebooks. Análisis reproducible.
- **Unidad 2**: Manipulación de datos con R. Importación y exportación de datos. Librería tidyverse. Gramática de manipulación de datos. Limpieza, normalización, combinación y resumen de datos numéricos y categóricos.
- **Unidad 3**: Visualizaciones, gráficos. Nociones generales sobre tipos de gráficos y sus usos. Introducción a ggplot2. La gramática de gráficos: estéticas, geometrías, escalas, temas, etc. Gráficos condicionales y multi-paneles.

- **Unidad 4**: Programación literaria. Generación de informes o reportes con Quarto/RMarkdown.

Sin más preámbulos… comencemos!

1 Introducción

1.1 La necesidad de analizar datos

Hoy en día los datos abundan y están en todos lados. Esto desafía nuestra capacidad para analizarlos y extraer significado de los mismos para tomar decisiones.

La ciencia de datos (data science) es una nueva disciplina que emerge de la combinación de disciplinas existentes (diagrama) y permite convertir datos sin procesar en entendimiento, comprensión y conocimiento.

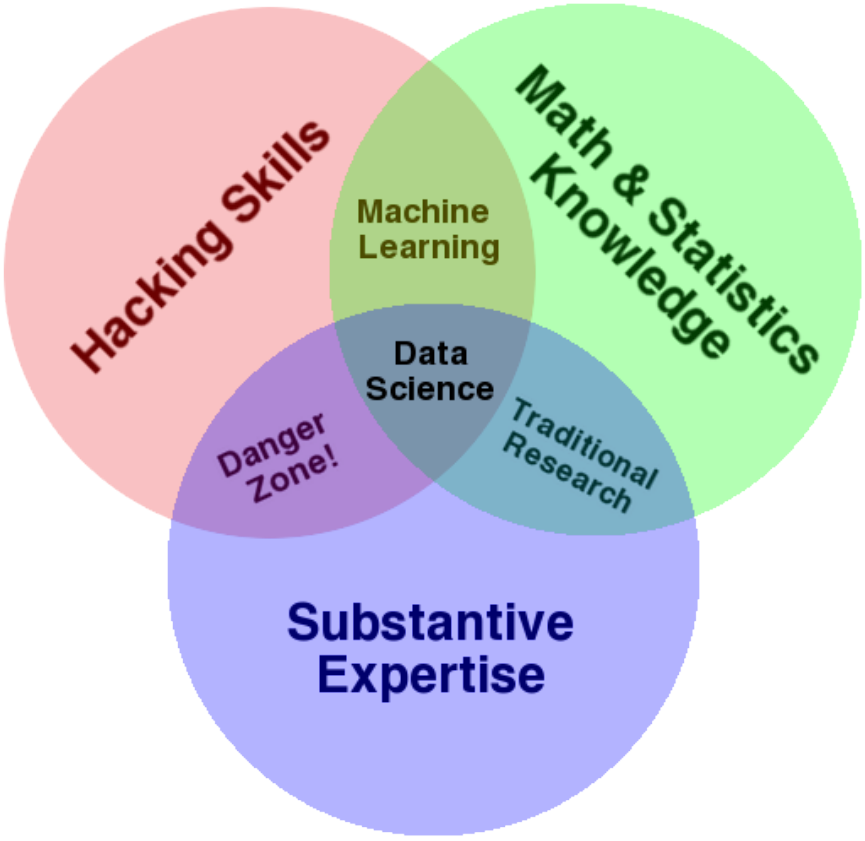

Figura 1.1: Diagrama de Venn de la Ciencia de Datos según Conway

Para poder analizar los datos de manera efectiva, es necesario tener conocimientos de disciplinas como ciencias de la computación (programación y más), matemática y estadística. Pero también tenemos que tener conocimientos para lograr el entendimiento del problema en estudio. La combinación de estas áreas nos lleva al concepto de Ciencia de Datos.

1.2 ¿Cómo es el flujo de analisis de datos?

Si bien el análisis de datos es un proceso no lineal que varía en cada situación, existe consenso en cuanto a las principales actividades que se deben desarrollar. El siguiente gráfico resume el flujo de trabajo o *workflow*.

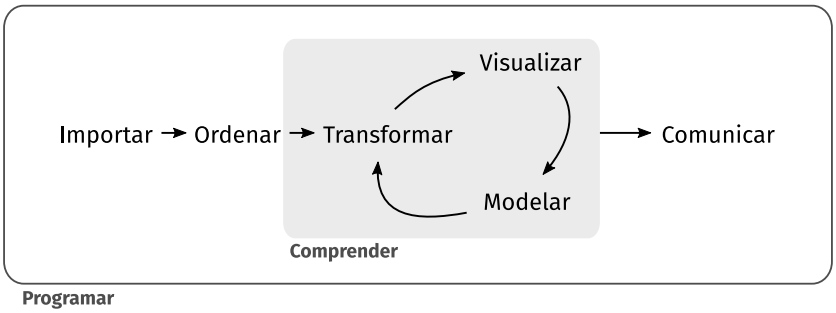

Figura 1.2: Diagrama de Venn de la Ciencia de Datos según Conway

Todo análisis comienza con importar datos a la herramienta que estemos utilizando, **R** en este caso. Los datos pueden estar almacenados de diferentes formas, como archivos, dentro de una base de datos o una API (*application programming interface*). En el curso veremos distintas formas de importar datos dentro de **R** en un formato compatible para su análisis.

Salvo excepciones, una vez importados los datos, hay que ordenarlos de alguna forma que permita realizar el análisis que queremos. En la mayoría de los casos necesitaremos que los datos estén almacenados de manera **rectangular** tal que cada columna represente una variable o atributo de los datos y cada fila una o más observaciones o sujetos (formato *apaisado*).

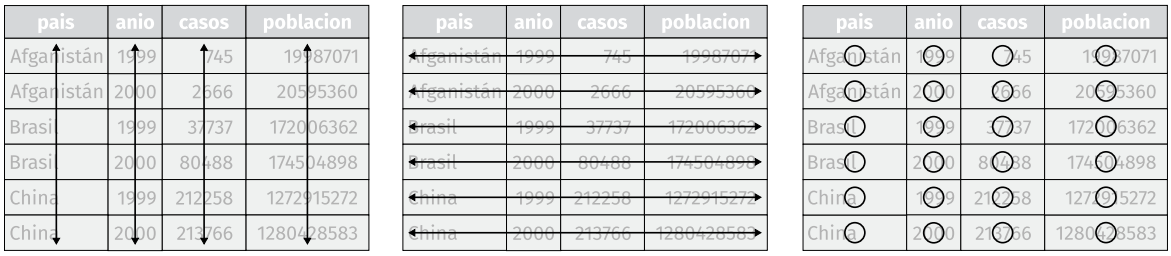

A veces cuando algunas columnas representan valores de una misma variable hay que modificar este formato y *pivotar* a un formato *longitudinal*.

Con los datos ordenados podemos concentrarnos en comprender su estructura y empezar a jugar con ellos. Esta etapa no es para nada lineal y generalmente implica un proceso iterativo donde los datos se visualizan, se transforman y se modelan.

La transformación de los datos implica crear subconjuntos o combinar con otros datos, alterar las variables existentes (e.g. cambiar unidades) o generar nuevos atributos combinando información de otros, resumir los datos agrupando observaciones, etc. El manejo de datos de datos (*data wrangling*) es la combinacion de técnicas de ordenamiento y transformación.

La visualización es el arte de convertir los datos de forma tabular en gráficos o diagramas donde los disintos atributos de los datos se relacionan a características gráficas tales como ejes, colores, formas, etc. Una buena visualización permitirá revelar patrones inesperados, confirmar alguanas peguntas o sugerir nuevas. Es muy util para comunicar.

El modelado es una forma de cuantificar lo podemos ver en una visualización. Al igual que las visualizaciones, los modelos son abstracciones de los datos y nos permiten resumir la variacion quedandonos con la generalidad. Los modelos son ultiles para contestar preguntas sobre los datos. Lo clave es hacer la pregunta correcta! Por otro lado los modelos son tan buenos como los datos de entrada y los supuestos utilizados.

El último paso de un proyecto de ciencia de datos es la comunicación. Esta etapa resume todo nuestro trabajo y determina como podemos transmitir nuestras conclusiones y descubrimientos a otros que no participaron del análisis.

Finalmente, todas y cada una de las etapas de este proceso se desarrollan con la ayuda de la programación. No es necesario ser un hacker, hay que saber pensar como un programador y saber programar ayuda a automatizar tareas.

1.3 ¿Que es un análisis reproducible?

En las Ciencias Experimentales, poder replicar los experimentos es un componente muy importante del método científico ya que le da validez a los descubrimientos. Es por ello que en los trabajos científicos, una sección importante es la de *Materiales y Métodos* donde se describen los pasos que se deben dar para poder *replicar* de los resultados del estudio. Estos pasos incluyen las instrucciones para replicar el experimento físico y de como *reproducir* el análisis de los datos que llevó a las conclusiones.

Así la **replicabilidad** implica que, siguiendo los *materiales y métodos* un experimento independiente puede llegar a los mismos resultados con datos distintos. En cambio la **reproducibilidad** significa que con la misma persona u otra persona con los mismos datos llegue a los mismos resultados, es decir, que pueda reproducir el análisis.

La Ciencia de Datos la **reproducibilidad computacional** es clave ya que en el procesamiento de datos se toman una serie de decisiones que afectan el resultado. ¿Qué significa esto? Dada una serie de datos de entrada, el flujo de trabajo que se aplica para *importar*, *ordenar*, *transformar*, *visualizar* y *modelar* los datos, es decir, convertirlos en información, debe estar correctamente **documentado** para que cualquier persona pueda entender la lógica y eventualemente reproducir los mismos resultados.

R, como cualquier lenguaje de programación, es una herramienta ideal para aplicar el concepto de **reproducibilidad** ya que mediante en el código o *script* quedan plasmados todos los pasos que se aplicaron en el análisis de datos. Más aun, el uso del paradigma de **programación literaria** permite generar documentos donde se narran todos los pasos y los resultados ontenidos.

2 Comenzando con R

En esta sección vamos a ver que es cómo instalar y cómo empezar a usar R y RStudio creando nuestro nuestro proyecto de análisis reproducible de datos.

2.1 ¿Qué es R y RStudio?

R es un lenguaje y entorno para el procesamiento, visualización y análisis estadístico de datos. Fue creado en 1993 por R. Gentleman y R. Ihaka, ambos científicos del Departamento de Estadística de la Universidad de Auckland (Nueva Zelanda). Actualmente su desarrollo y mantenimiento está a cargo del R Core Team (2023). El sitio oficial del proyecto es www.r-project.org.

Hoy en día, **R** es la *lingua franca* del procesamiento y análisis de datos, tanto en el ámbito académico como comercial dado que es gratiuto, multiplataforma, de código abierto (*open source*, liberado con licencia GNU/GPL). Esto y el ecosistema de paquetes contribuidos por la comunidad de usuarios lo convierte en un software muy potente ya que expresa el estado del arte de los métodos estadísticos.

La flexibilidad y potencia de **R** se basa en su interfaz de comandos (CLI, del inglés *command line interface*) que permite la ejecución de comandos de manera interactiva (en consola) o estructurada mediante scripts.

Existen algunos desarrollos de interfases gráficas (GUIs, del inglés *graphical user interface*), e.g. RCommander, Deducer, etc., que ofrecen la posibilidad de, mediante menúes y botones dedicados, ejecutar algunos análisis relativamente simples minimizando la necesidad de escribir código.

Los entornos de desarrollo integrados (IDE por sus siglas en inglés *integrated development environments*) ofrecen un enfoque intermedio: los menúes o funciones asistentes facilitan algunas tareas generales (abrir archivos, carga de datos, exportar gráficos y resultados, etc.) pero dejan la escritura del código y ejecución del análisis estadístico en manos del usuario. Entre estas alternativas se destaca **RStudio** desarrollado por la empresa posit el cual también es de código abierto (licencia GNU/GPL), multiplataforma y ofrece una versión gratuita.

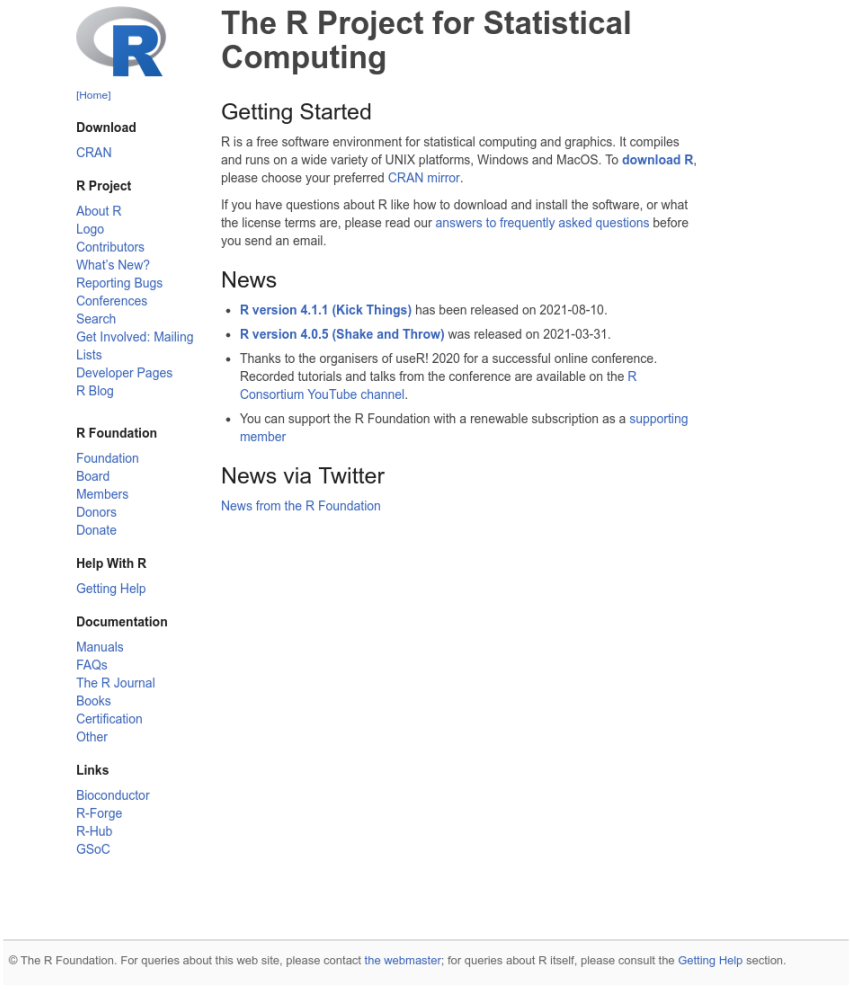

Figura 2.1: Página oficial de R Project

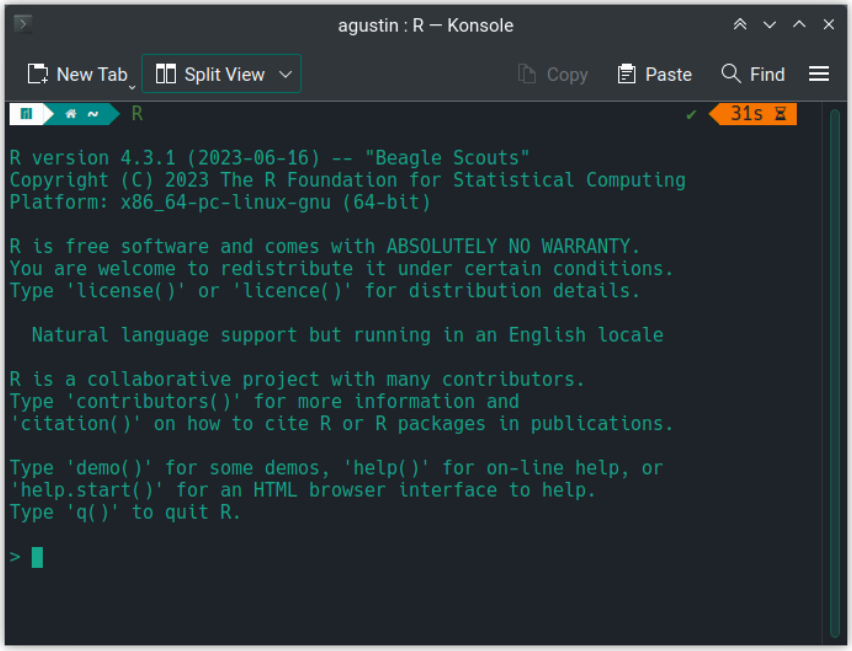

Figura 2.2: Ejemplo de consola o terminal de Linux y Windows corriendo la última versión estable de **R**

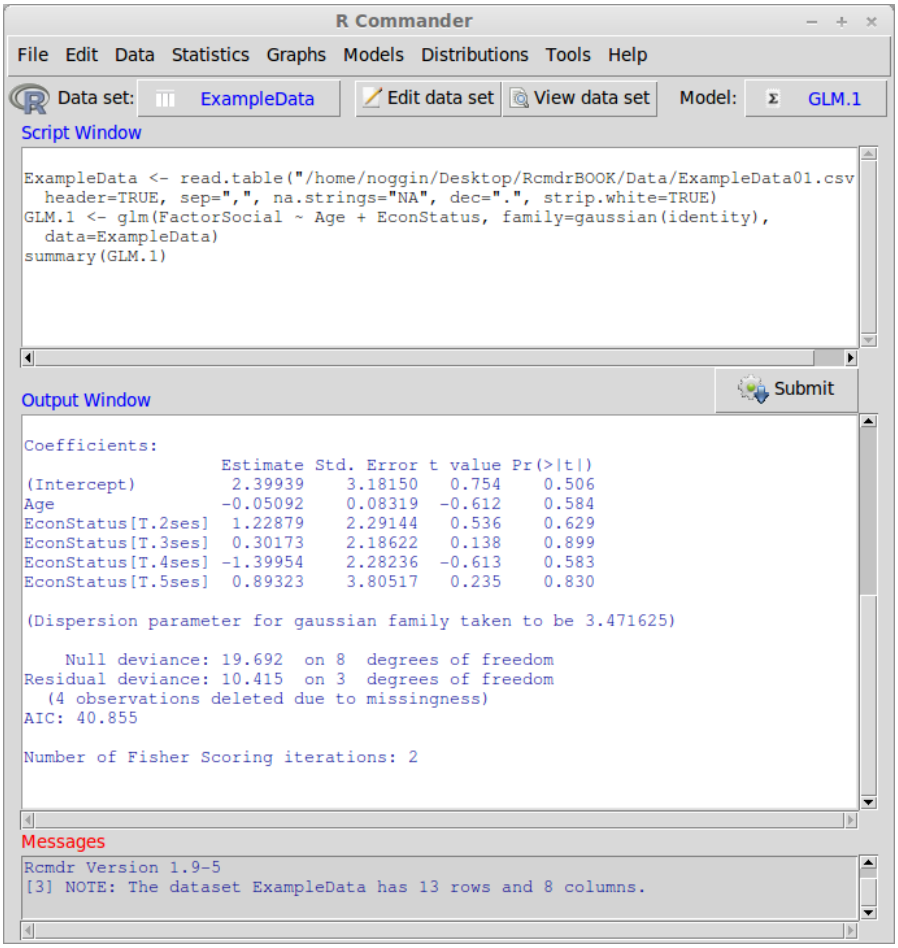

Figura 2.3: Interfase de **R** Commander

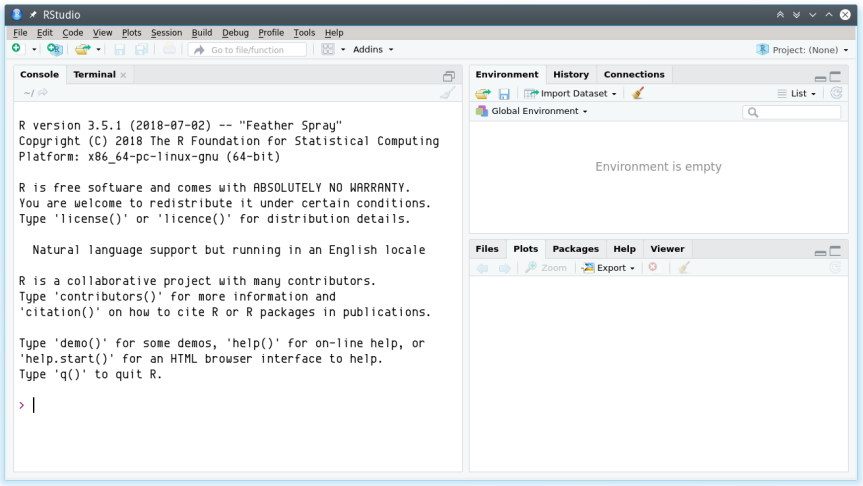

Figura 2.4: Interfase de **RStudio**

2.2 ¿Cómo instalar R y RStudio?

R y **RStudio** se instalan por separado. Ambos softwares son multiplataforma y pueden ser ejecutados en sistemas operativos Windows, Mac OS X y Linux.

R puede funcionar sin **RStudio**, en cambio **RStudio** necesita que al menos una versión de **R** esté instalada en el sistema.

La página de descarga de **posit** https://posit.co/download/rstudio-desktop/ ofrece un excelente punto de partida para instalar ambos programas.

Figura 2.5: Página de descaga de **R**

A continuación se describe el procedimiento para instalar **R** y **RStudio** bajo Windows.

2.2.1 Instalación de R

1) Click en el botón `DOWNLOAD AND INSTALL R`:

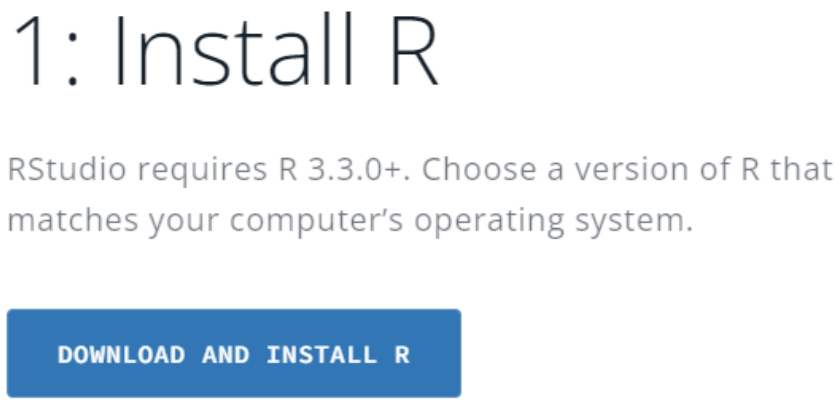

Figura 2.6: Página de descaga de **R**

Descargar el archivo instalador correspondiente a la última versión estable de **R** desde el CRAN[1] (del inglés, *Comprenhensive R Archive Network*) visitando el siguiente link.

2) Ejecutar el archivo descargado [2] y seguir el asistente de instalación con todas las opciones por defecto.

3) Si la instalación ha sido exitosa en el menú *Inicio* podrá encontrarse la carpeta *R* que contendrá dos accesos directos a la interfase de usuario mínima que viene con la versión de **R** para Windows.

2.2.2 Instalación de RStudio

1) Click en el botón `DOWNLOAD RSTUDIO DESKTOP FOR ......`:

Descargar el archivo de instalación correspondiente a nuestra plataforma o sistema operativo. Al momento de escribir estas instrucciones la última versión estable de **RStudio** era `RStudio-2023.09.0-463.exe` que se encuentra en este link

En el caso que haya una nueva versión, ir al sitio web de descarga de **RStudio** https://posit.co/download/rstudio-desktop/

2) Ejecutar el archivo `.exe` y seguir el asistente de instalación con todas las opciones por defecto.

[1] Si bien `<-` funciona igual que `=` en la mayoría de los casos, por convención se usa `<-` para asignar y `=` para argumentos dentro de las funciones.

[2] Al momento de escribir estas instrucciones la última versión estable de **R** era la 4.3.1 *Beagle Scouts*, por lo tanto el link apuntará al archivo `R-4.3.1-win.exe`.

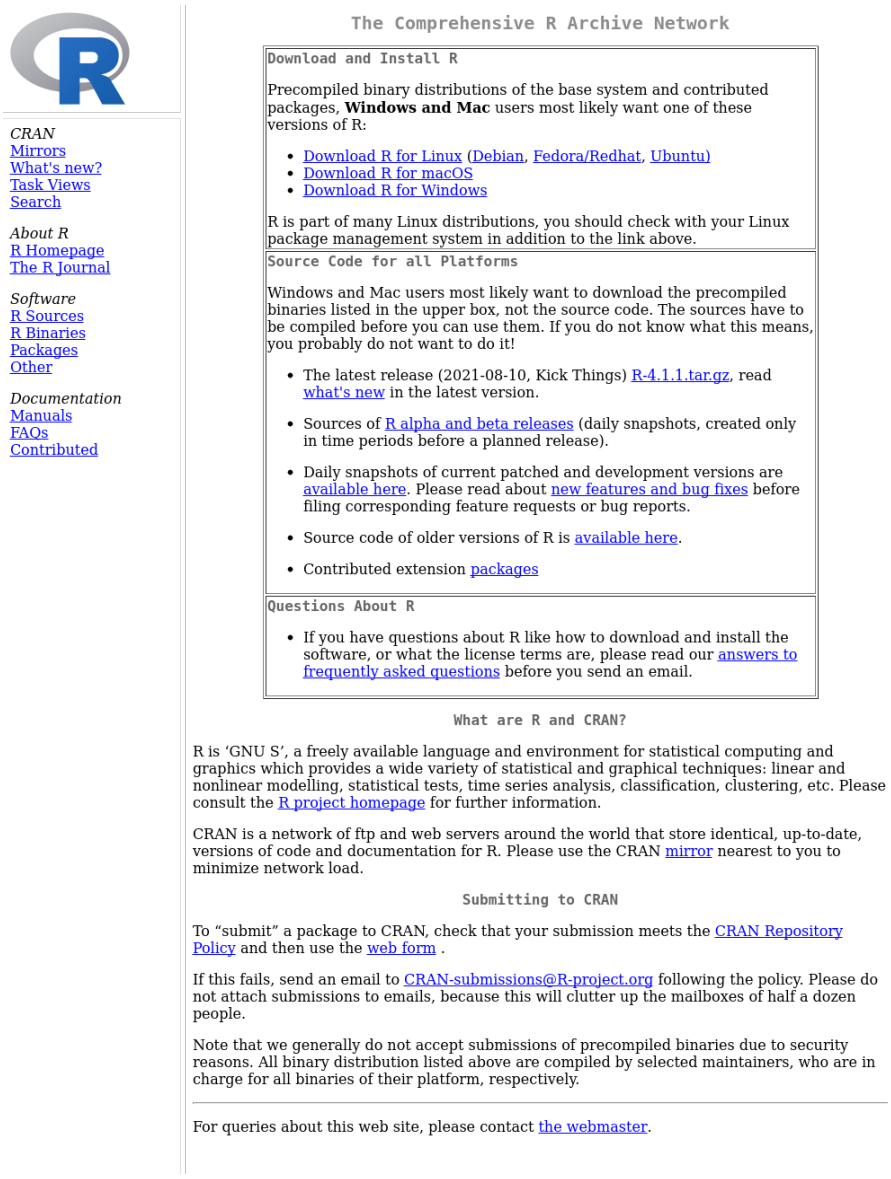

Figura 2.7: Página de descaga de **R**

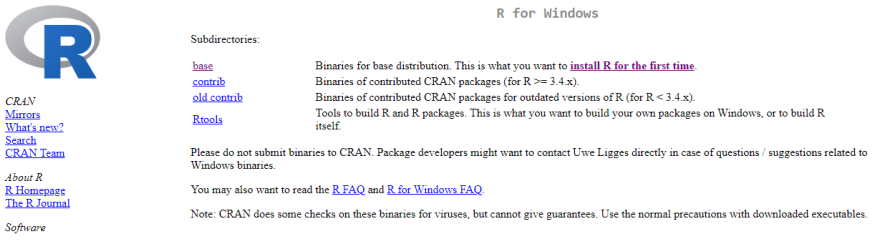

Figura 2.8: Dirigirse a Install R for firt time

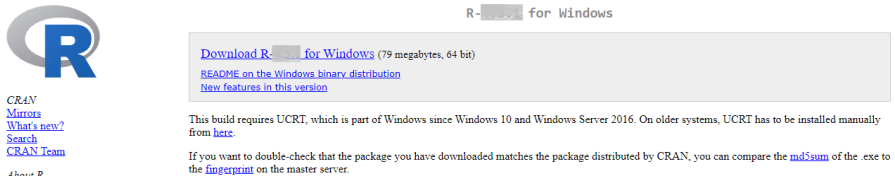

Figura 2.9: Dirigire a "Download R-X.X.X for Windows"

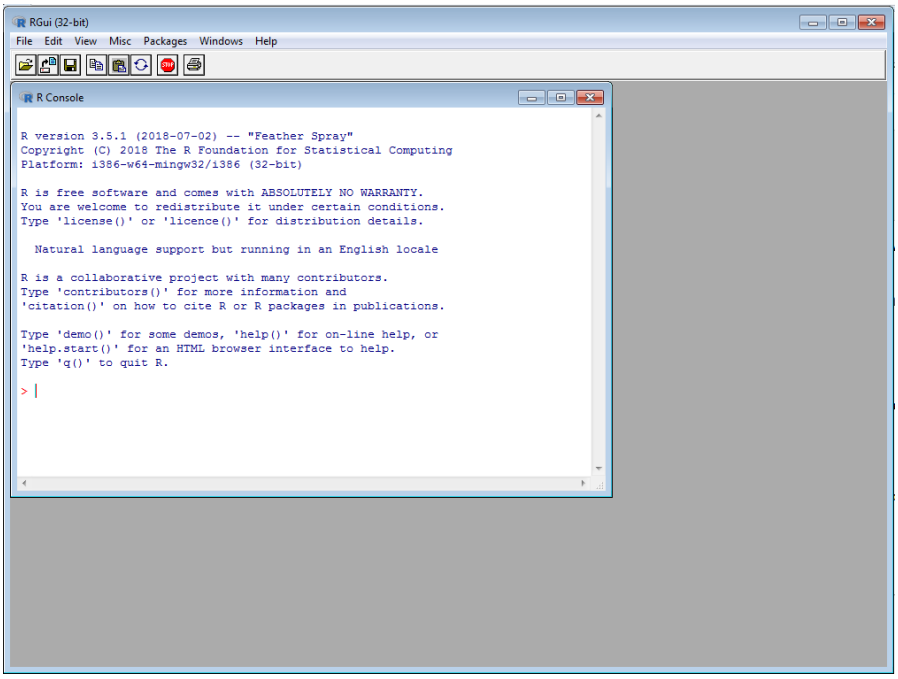

Figura 2.10: R GUI para Windows

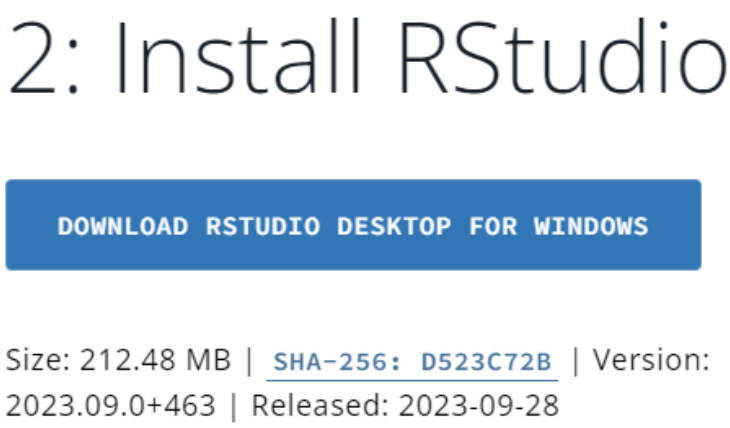

Figura 2.11: Página de descaga de **R**

3) Si la instalación ha sido exitosa en el menú *Inicio* dentro de la carpeta *RStudio* se encontrará el acceso directo a **RStudio** el cual, mediante el menu contextual (botón derecho del ratón) puede enviarse al Escritorio como acceso directo o bien anclar al menu de Inicio o barra de acceso rápido.

Ahora sí, ya tenemos listo **R** y **RStudio** para empezar a trabajar!!

ACTIVIDAD

1. Instalar **R** y **RStudio**

2.3 Primera sesión

El entorno de trabajo de **RStudio** se divide en cuatro paneles. La disposición y contenido de los paneles se puede personalizar yendo a `View > Panes > Panes Layout...`. A continuación la descripción de los paneles principales:

1. **Editor**. Es donde se editan los *scripts* que son archivos de texto plano con los comandos para ejecutar en **R**. Este panel no aparece a menos que se cree un nuevo script o se abra uno previamente guardado.
2. **Console** (consola). Es donde vive **R** propiamente dicho. Allí se ejecutan los comandos y se obtienen las salidas de **R**.
3. **Environmnet/History/Connections**. En la primera pestaña se visualizan los objetos (variables, funciones o datos cargados) que están disponibles en el entorno de **R**, i.e. en

RStudio Desktop 1.4.1717 - Release Notes

1. Install R. RStudio requires R 3.0.1+.

2. Download RStudio Desktop. Find your operating system in the table below.

All Installers

Linux users may need to import RStudio's public code-signing key prior to installation, depending on the operating system's security policy.

RStudio requires a 64-bit operating system. If you are on a 32 bit system, you can use an older version of RStudio.

OS	Download	Size	SHA-256
Windows 10	RStudio-1.4.1717.exe	156.18 MB	71b36e64
macOS 10.14+	RStudio-1.4.1717.dmg	203.06 MB	2cf2549d
Ubuntu 18/Debian 10	rstudio-1.4.1717-amd64.deb	122.51 MB	e27b2645
Fedora 19/Red Hat 7	rstudio-1.4.1717-x86_64.rpm	138.42 MB	648e2be0
Fedora 28/Red Hat 8	rstudio-1.4.1717-x86_64.rpm	138.39 MB	c76f620a
Debian 9	rstudio-1.4.1717-amd64.deb	123.29 MB	e4ea3a60
OpenSUSE 15	rstudio-1.4.1717-x86_64.rpm	123.15 MB	e69d55db

Zip/Tarballs

OS	Zip/tar	Size	SHA-256
Windows 10	RStudio-1.4.1717.zip	227.77 MB	84b1dc1a
Ubuntu 18/Debian 10	rstudio-1.4.1717-amd64-debian.tar.gz	177.14 MB	ba24900c
Fedora 19/Red Hat 7	rstudio-1.4.1717-x86_64-fedora.tar.gz	177.24 MB	4c05ddca
Debian 9	rstudio-1.4.1717-amd64-debian.tar.gz	177.48 MB	cd6d8462

Source Code

A tarball containing source code for RStudio 1.4.1717 can be downloaded from here.

Figura 2.12: Página de descarga de **RStudio**

Figura 2.13: Icono de **RStudio**

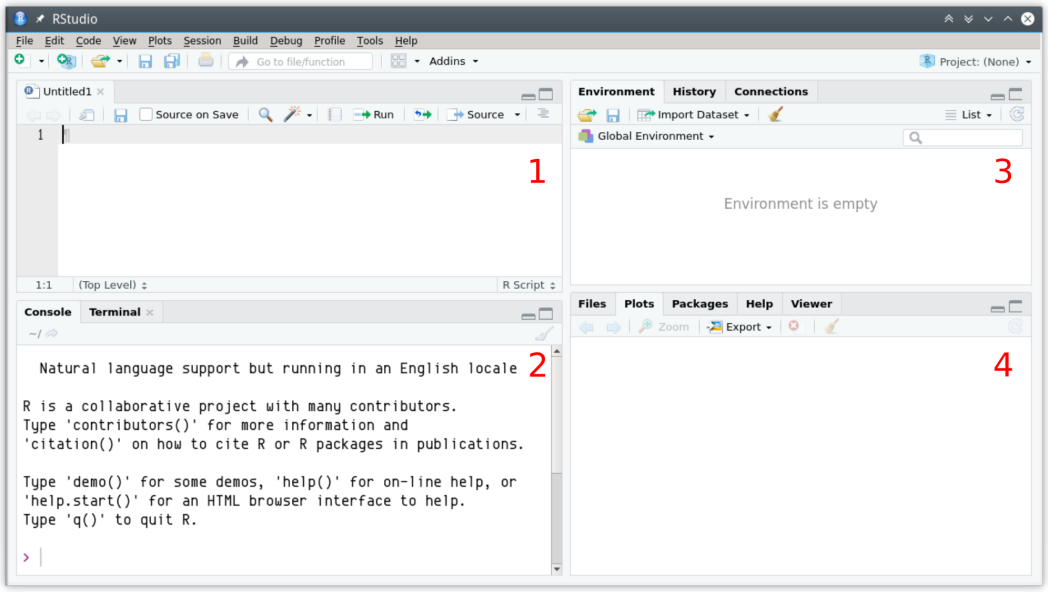

Figura 2.14: Interfase principal de **RStudio**

la memoria. En la segunda se puede ver el historial de comandos ingresados o enviados a la consola. La tercera pestaña visualiza las conexiones establecidas con diferentes base de datos.

4. **Files/Plots/Packages/Help/Viewer**. Allí se puede manejar los archivos del directorio de trabajo, visualizar los gráficos generados en **R** con posibilidad de exportarlos en varios formatos, administrar los paquetes o complementos, buscar o explorar el manual de ayuda y previsualizar archivos HTML.

2.3.1 La consola

La línea de comandos o **consola** es el modo interactivo mediante el cual podemos ejecutar comandos directamente en el intérprete de **R**. El símbolo o *prompt* `>` indica que **R** está disponible esperando una orden. Si la orden no está completa el símbolo se transforma en `+`. Por ejemplo: si tipeamos `2 + 2` y luego `ENTER`:

```
2 + 2
```

```
[1] 4
```

Obetenemos inmediatemente el resultado. Otro ejemplo: el promedio de los números `1`, `3` y `4`

```
(1 + 3 + 4) / 3
```

```
[1] 2.666667
```

ACTIVIDAD

1. Escribir una operacion matemática, por ejemplo: `3*4`
2. Escribir algo en la consola. ¿Que sucede?
3. Escribir lo anterior entre comillas `" "`.

2.3.2 El script

El **editor de scripts** (panel #1) es un editor de texto plano que está conectado con la consola (panel #2). Tiene algunas funcionalidades que facilitan la edición del código:

- Resaltado sintaxis: mediante colores resalta las funciones, variables, comandos o palabras claves del lenguaje **R**
- Sangrado automático: agrega espacios en blanco para mantener la sangría de los bloques de código.
- Plegado de código: permite colapsar bloques de código
- Completado automático y ayuda en linea: muestra sugerencias para completar el comando o argumentos usando la tecla `TAB`.

Para crear un nuevo script se puede usar uno de los siguientes métodos:

- Ir a al menu `File > New File > R Script`
- Usar el atajo de teclado `CTRL + SHIFT + N`
- Clickear en el primer ícono de la barra de menu

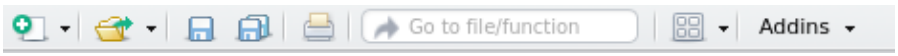

Figura 2.15: Barra de herramientas de **RStudio**

Una vez abierto el script en blanco, se pueden empezar a escribir los comandos de **R**. Por ejemplo podemos escribir lo siguiente:

```
"Hola Mundo!" # Clásico mensaje "Hola mundo!"

# Calcular el promedio de estos números
(1 + 3 + 4) / 3
```

Estos comandos no se van a ejecutar automáticamente ya que sólo los hemos escrito en el *script*. Para ejecutar los comandos en la consola hay que posicionar el cursor en la línea deseada o bien seleccionar si queremos ejecutar varias a la vez y luego enviarlo a la consola con una de las siguientes opciones:

- Ir al menu `Code > Run Selected Line(s)`
- Usar el atajo de teclado `CTRL + ENTER` o `CTRL + R`
- Usar el ícono `Run` de la barra de herramientas de la pestaña del script

Figura 2.16: Barra de herramientas del panel Editor

El simbolo `#` indica que lo que sigue es un **comentario** y por lo tanto **R** lo ignora cuando es enviado a la consola. Los comentarios pueden ir solos en una línea separada o bien dentro de una línea que tenga algún comando. Si bien no son necesarios para correr el código, los

comentarios son muy útiles para estructurar el script y hacer anotaciones para que otros, o nosotros en un futuro, entiendan lo que hace esa parte del script.

Para guardar el script:

1. Ir al menu `File > Save` o usar el atajo de teclado `CTRL + S` o bien el ícono con el diskette de la barra de herramientas global o de la pestaña del script activo.
2. Elegir la carpeta destino y el nombre de archivo. Automáticamente se agregará la extensión `.R` que corresponde a los scripts.

ACTIVIDAD

1. Abrir un script nuevo
2. Escribir un comentario
3. Escribir un texto o un comando numérico
4. Guardar el script con el nombre `mi_primer_script.R`.

2.3.3 Directorio de trabajo y proyectos

R trabaja con un directorio de trabajo o *working directory* que es la dirección o *path* que figura en el titulo del panel **Console**. Esto se puede averiguar con `getwd()`

```
getwd()
```

Por defecto es el directorio base del usuario que depende de cada plataforma. En linux es el `/home/usuario` en cambio en Windows es `C:/Users/usuario/Documents`.

A menos que se especifique lo contrario, se asume que los archivos de entrada o salida se ubican en esa. Esto se puede modificar en cualquier momento con la función `setwd()`.

```
setwd("ruta/a/otra/carpeta")
```

RStudio extiende esta característica a través de los proyectos o *projects*. Cada proyecto es una carpeta o *folder* que contienen un archivo `.RProj` con algunas configuraciones específicas.

Al abrir un proyecto, automáticamente se cambia el directorio de trabajo a esta carpeta. Esto permite organizar los archivos de datos, las salidas, los scripts, etc., dentro de un directorio de trabajo (*working directory*) y volver a ellos de manera más rápida, eficiente, y portable.

Para crear un proyecto en **RStudio**:

1. Ir a `File > New project...` o bien el ícono `Create project` de la barra de herramientas.

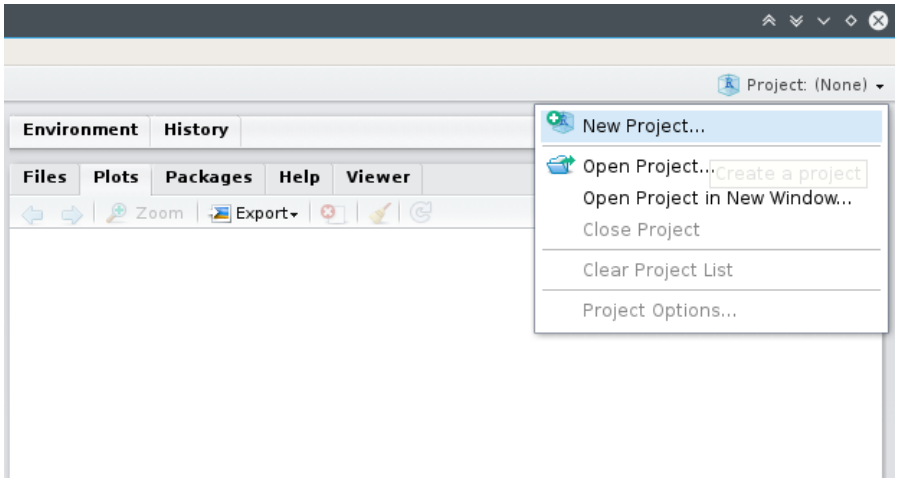

2. Seleccionar `New Directory` y en `Project type` seleccionar `New project`.

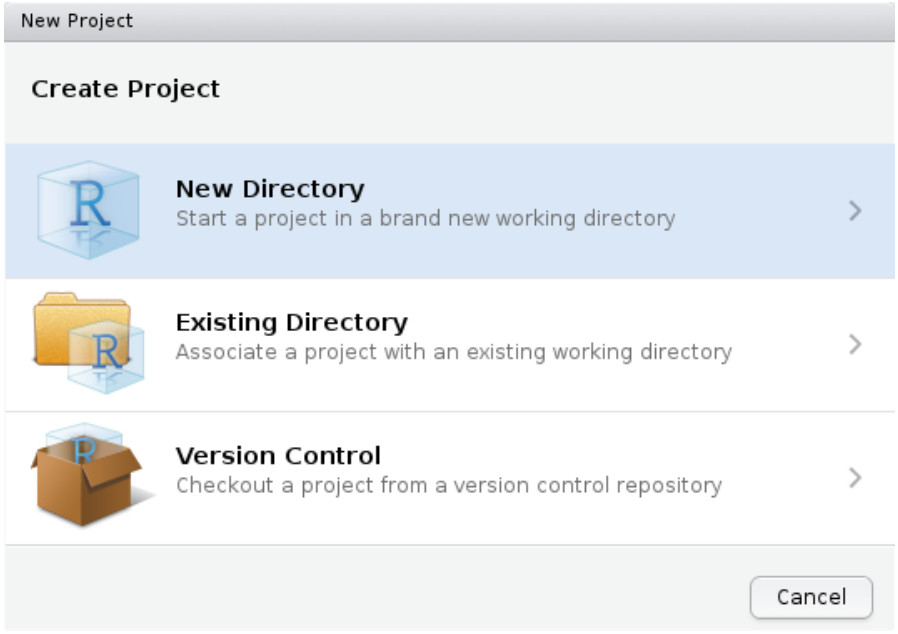

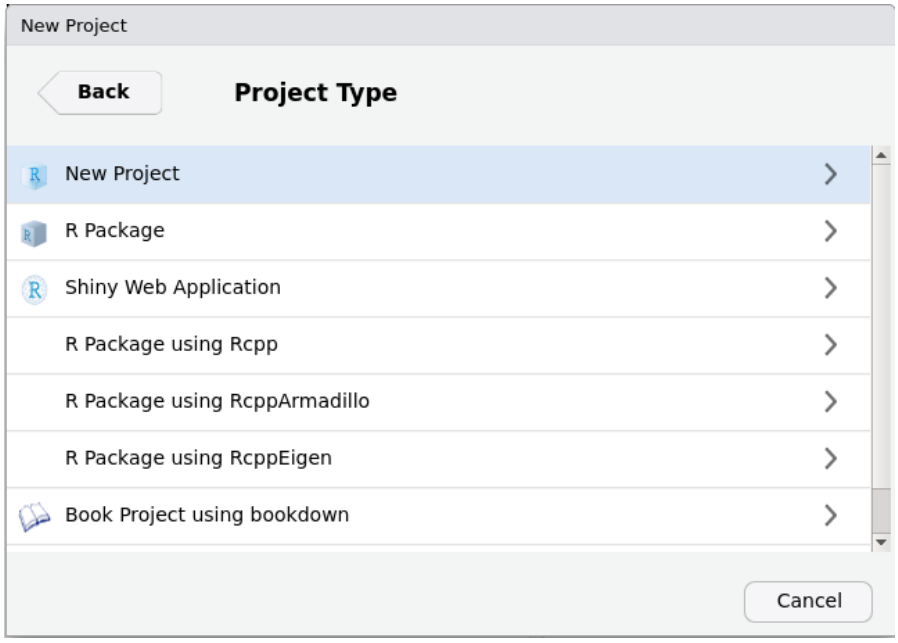

3. Una vez en el cuadro de diálogo `Create new project` ingresar el nombre del proyecto (e.g. `mi_proyecto`) en `Directory name` que será a su vez el nombre de la carpeta que **RStudio** va a crear por nosotros.

   Luego en `Create project as a subdirectory of` indicar *donde* queremos que **RStudio** cree la carpeta.

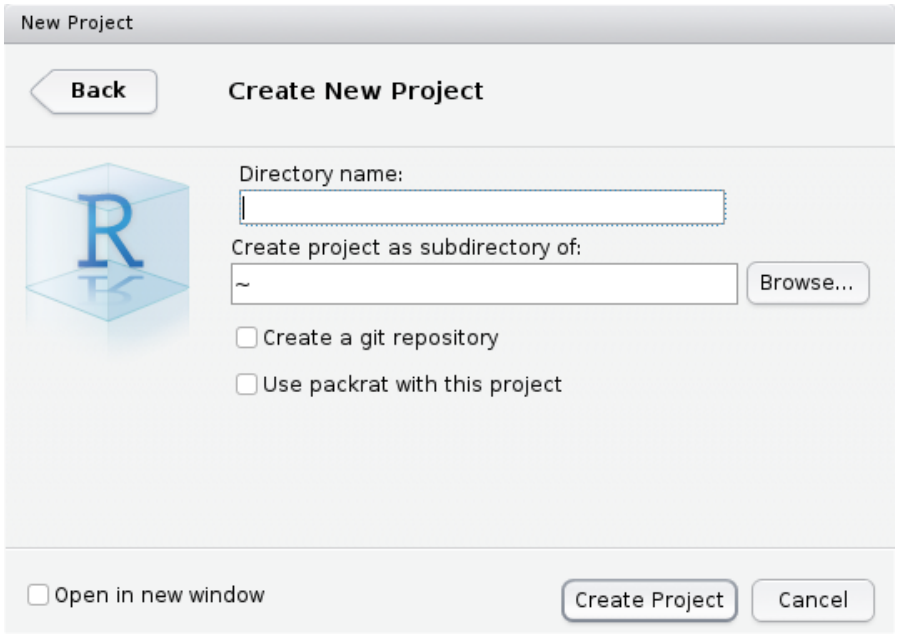

4. Si todo sale bien, se crea la carpeta con el nombre que indicamos y dentro de ésta un archivo con extensión `.Rproj`. Este archivo solamente se usa para abrir el directorio. No se debe sobreescribir con el script.

ACTIVIDAD

1. Crear un proyecto nuevo con el nombre "Intro_R" en el escritorio o lugar de preferencia.
2. Cerrar **Rstudio**.
3. Abrir **Rstudio** desde el proyecto.
4. Copiar el script creado en la actividad anterior dentro del nuevo proyecto.
5. Abrir el script.

2.3.4 Ayuda!!!

Por último, y no menos importante, **R** y **RStudio** cuentan con un completo sistema de ayuda.

Desde la consola se puede acceder usando la función `?` seguida del nombre de la función o bien `help("nombre")`

```
# Pedir ayuda de la función mean
?mean
help(mean)
```

Una de las ventajas de **RStudio** es que dispone de un panel (Panel #4) dedicado a visualizar las páginas de ayuda. Allí se puede navegar por las páginas utilizando los links, realizar búsquedas, etc. Leer la documentación nunca viene mal y generalmente ahorra dolores de cabeza.

3 Aspectos básicos de R

En esta sección vamos a aprender nociones básicas de la sintaxis de R, tipos de datos y estructuras.

3.1 Operadores matemáticos y lógicos

Como vimos antes, las operaciones matemáticas básicas se realizan usando los símbolos convencionales:

- suma (`+`)
- resta (`-`)
- división (`/`)
- producto (`*`)
- potencia (`^`)

Por ejemplo, $1 + \left(3 \times 4 + \frac{5-2}{3}\right)^2$ en **R** es:

```
1 + (3 * 4 + (5 - 2)/3)^2
```

```
[1] 170
```

También se pueden evaluar expresiones lógicas:

- *igual que* (`==`)
- *distinto que* (`!=`)
- *mayor que* (`>`)
- *menor que* (`<`)
- *mayor o igual que* (`>=`)
- *menor o igual que*(`<=`)

El resultado es `TRUE` (verdadero) o `FALSE` (falso). Por ejemplo, podemos evaluar si 3 es igual 4

```
3 == 4
```

```
[1] FALSE
```

O si 5 es mayor o igual a 3

```
5 >= 3
```

```
[1] TRUE
```

También se pueden combinar con los operadores *intersección* (`&`), *unión* (`|`) y *negación* (`!`).

Por ejemplo, evaluar si se cumplen las dos cosas anteriores a la vez

```
3 == 4 & 5 >= 3
```

```
[1] FALSE
```

Devuelve `FALSE` porque `3 == 4` no es verdadero. Si reemplazamos `&` por `|` va a devolver evaluar si una de las dos se cumple:

```
3 == 4 | 5 >= 3
```

```
[1] TRUE
```

También se pueden combinar con operaciones matemáticas...

```
4 * 2 == 8
```

```
[1] TRUE
```

En este caso primero evalúa `4 * 2` y luego compara el resultado con `8`

ACTIVIDAD

1. Hallar el resultado de la siguiente expresión $(2+4)^2$ y 2^2+4^2.
2. Comparar ambos resultados en una linea de comando.

3.2 Variables y objetos

Un objeto es un espacio de la memoria que almacena un pedazo de información (una cifra, un conjunto de números, el resultado de un análisis, etc). También se denomina *variables* ya que su contenido puede cambiar. En **R** prácticamente todo puede representarse como un *objeto*.

Los objetos o variables se crean *asignándoles* información (números, letras, resultados de operaciones, etc), con el símbolo `<-` (`ALT + -`) o `=`[1]. Esta informacion se puede recuperar, modificar o utilizar para otros cálculos.

Supongamos que queremos asignar el valor 2 a la variable `x`.

```
x <- 2
```

En la consola vuelve a aparecer el simbolo `>` y nada más. En el ambiente se ve una entrada que dice `x` y el valor. Podemos recuperar el valor en la consola tipeando el nombre del objeto:

```
x
```

```
[1] 2
```

También podemos reusarlo en otro calculo, por ejemplo obtener 2 veces `x`.

```
2 * x
```

```
[1] 4
```

O bien obtener una nueva variable

```
y <- 2 * x +1
y
```

```
[1] 5
```

> **Nombres**
>
> Los nombres de las variables no deben empezar con números ni contener espacios. No pueden usarse operadores (`*+-/&%`) en los nombres pero puede usarse `.` o `_`.

[1] Si bien `<-` funciona igual que `=` en la mayoría de los casos, por convención se usa `<-` para asignar y `=` para argumentos dentro de las funciones.

```r
# Mal
2x <- 3
mi variable <- 3

# Bien
x_2 <- 3
x.2 <- 3
x2 <- 3
```

Mayúsculas

También **R** es sensibles a mayúsculas

```r
# Definir 'A' y 'a'
A <- 3
a <- 5

# Verificar si 'A' y 'a' son lo mismo
A == a
```

```
[1] FALSE
```

3.2.1 Vectores

Son los objetos más simples a partir de los cuales se construyen otros tipos de objetos. Se crean utilizando la función `c()` (*combine*) para "combinar" **datos del mismo tipo**

```r
x <- c(13, 45, 67, 45)
x
```

```
[1] 13 45 67 45
```

En el caso de mezclar de datos, **R** los va a *convertir* al tipo de datos más simple.

Por ejemplo: si queremos crear un vector con 3 valores: lógico, numérico y texto, **R** va a asumir que todos los elementos son de tipo *texto*

```r
y <- c(TRUE, 34, "hola")
y
```

```
[1] "TRUE" "34"   "hola"
```

Los vectores están indexados. Se puede acceder a sus elementos usando el operador `[ ]` e indicando el número de orden.

Por ejemplo: para recuperar el 3er elemento del vector `x`

```
y[3]
```

```
[1] "hola"
```

Veremos más adelante los distintos tipos.

3.2.2 Funciones y argumentos

Para crear los vectores sin pensarlo utilizamos una funcion `c()`. Las funciones son series de comandos que hacen alguna acción y producen un resultado.

Generalmente tienen la siguiente la siguiente forma:

`nombre_funcion(arg1, arg2, ...)`

donde `arg` son los argumentos (valores de entrada u opciones). Algunos argumentos toman valores por defecto otros hay que declararlos.

Por ejemplo, la función `round`()‘ tiene los argumentos:

- `x`, para pasar el número o vector numérico que queremos redondear
- `digits = 0` para indicar el numero de dígitos a usar, por defecto 0.

Supongamos que queremos redondear el numero `3.141593` a 3 dígitos. Para eso usamos la función `round()` (buscar en la ayuda `?round`)

```
# Indicando los argumentos
round(x = 3.141593, digits = 3)
```

```
[1] 3.142
```

```
# Sin indicar los argumentos
round(3.141593, 3)
```

```
[1] 3.142
```

En este último caso, el orden de los argumentos es clave ya que **R** asigna los valores en función de la posición.

```
# Sin indicar los argumentos
round(3, 3.141593)
```

```
[1] 3
```

Devuelve `3` por considera que queremos redondear el número `3`

3.2.3 Creando funciones

Así como **R** tiene viene con funciones ya definidias, nosotros podemos crear nuestras propias funciones para poder simplificar nuestro analisis encapsulando tareas repetitivas.

Por ejemplo, supongamos que queremos calcular el área de 3 rectángulos cuyas dimensiones son:

- Rectangulo 1: base = 10, altura = 20
- Rectangulo 1: base = 15, altura = 35
- Rectangulo 1: base = 20, altura = 5

Sabemos que la fórumla del área es: $A = b \times a$, donde A es el area, b es la base y a es la altura.

Podríamos hacer:

```
10 * 20
```

```
[1] 200
```

```
15 * 35
```

```
[1] 525
```

```
20 * 5
```

```
[1] 100
```

Como vimos antes podemos usar vectores y operar con ellos:

```r
bases <- c(10, 15, 20)
alturas <- c(20, 35, 5)
bases * alturas
```

```
[1] 200 525 100
```

Yendo un poco mas lejos, en vez de repetir siempre la operación podríamos encapsularla en una *función*. Las funciones se crean con `function()` o `\()` y adentro se declaran los argumentos. Por defecto la función devuelve el ultimo comando o bien lo que se indique en `return()`

```r
area_rectangulo <- function(base, altura) {

  # Calculo sueperficie
  area <- base * altura

  return(area)

}
```

R no devuelve nada porque lo que hizo fue crear la función, a continuación podemos usarla:

```r
area_rectangulo(40,50)
```

```
[1] 2000
```

```r
area_rectangulo(bases, alturas)
```

```
[1] 200 525 100
```

ACTIVIDAD

1. Crear una función que calcule el area de un círculo. Tip: la constante π en **R** está en el objeto `pi`.
2. Avanzado: crear una función más avanzada llamada *area* que calcule el área de un rectángulo o círculo indicando en el argumento `figura` y suminisitrando el dato de base y altura o altura, según corresponda.
3. ¿Cómo podríamos expandirla para controlar el número de decimales de la respuesta?

4. ¿Por qué este código no funciona?

```
my_variable <- 10
my_variable
```

3.3 Tipos de datos

3.3.1 Numéricos (`numeric`)

Números racionales (enteros o con coma).

```
x <- c(3, 4, 5)
class(x)
```

```
[1] "numeric"
```

Los números enteros se tratan como `numeric` a menos que se los convierta con `as.integer()`.

```
y <- as.integer(x)
class(y)
```

```
[1] "integer"
```

Los datos numéricos permiten todas las operaciones algebráicas

```
mean(x)
```

```
[1] 4
```

```
mean(y)
```

```
[1] 4
```

3.3.2 Texto (`character`)

Cadenas de texto o número delimitadas por comillas (simples o dobles, nom mezclar).

```r
x <- c("hola", '3')
class(x)
```

```
[1] "character"
```

Lógicamente no se pueden realizar operaciones numéricas. **R** avisa y devuelve `NA`

```r
mean(x)
```

```
Warning in mean.default(x): argument is not numeric or logical: returning NA
```

```
[1] NA
```

3.3.3 Lógicos (`logic`)

Condición verdadero (`TRUE` o `T`) o falso (`FALSE` o `F`)

```r
logico <- c(T, F, T, TRUE, FALSE, F)
logico
```

```
[1]  TRUE FALSE  TRUE  TRUE FALSE FALSE
```

Otro ejemplo: ¿cuáles de los siguientes números son mayores a 30?

```r
x <- c(23, 43, 21, 34, 56, 3, 23, 3)
x > 30
```

```
[1] FALSE  TRUE FALSE  TRUE  TRUE FALSE FALSE FALSE
```

3.3.4 Factores (`factor` y `ordered`)

Si los elementos de vector de tipo texto (`character`) y representan niveles nominales (categorías), el objeto puede convertirse a `factor` de modo tal que los valores son reemplazados por un número que se asocia a los niveles del factor (ordenados alfabeticamente, a menos que se indique otra cosa).

Un ejemplo de un vector tipo `character`.

```
x <- c('bajo', 'medio', 'alto', 'alto', 'bajo', 'bajo')
x
```

```
[1] "bajo"  "medio" "alto"  "alto"  "bajo"  "bajo"
```

Sólo se muestran los valores (`bajo`, `medio` y `alto`). No hay información de niveles. Ahora si aplicamos `factor(x)`:

```
y <- factor(x)
y
```

```
[1] bajo  medio alto  alto  bajo  bajo
Levels: alto bajo medio
```

Los valores pasaron al atributo `levels` y los datos fueron reemplazados por los identificadores `2`, `3`, y `1` según el orden alfabético de los niveles.

```
as.numeric(y)
```

```
[1] 2 3 1 1 2 2
```

Cuando los niveles tienen una jerarquía u orden, se puede especificar este tipo de relación mediante `as.ordered()` que convierte el `factor` en uno especial `ordered` agregando la relación entre los niveles

```
z <- factor(x, levels = c('bajo', 'medio', 'alto'))
z <- as.ordered(z)
z
```

```
[1] bajo  medio alto  alto  bajo  bajo
Levels: bajo < medio < alto
```

Los factores como cualquier vector también se indexan con `[ ]`.

3.3.5 Otros tipos de datos

Los valores faltantes se simbolizan en **R** con `NA` (*not available*). Indican que debería haber un valor pero que está faltando.

```r
x <- c(1, 2, 3, NA, 4)
is.na(x)
```

```
[1] FALSE FALSE FALSE  TRUE FALSE
```

A diferencia del `NA`, un valor de tipo `NULL` indica que no hay información y que tampoco se esperaba que la haya.

```r
x <- c(1, 2, 3, NULL, 4)
x
```

```
[1] 1 2 3 4
```

Algunas operaciones matemáticas devuelven valores `NaN` (*not a number*) cuando no están definidas, por ejemplo:

```r
0/0
```

```
[1] NaN
```

O bien valores infinitos (`Inf`):

```r
1/0
```

```
[1] Inf
```

ACTIVIDAD

1. Ingrese lo siguiente en un vector con el nombre `color`: púrpura, rojo, amarillo, marrón
2. Mostrar el segundo elemento en el vector (rojo) en la consola.
3. Ingrese lo siguiente en un vector con el nombre `peso`: 23, 21, 18, 26

3.4 Estructura de datos

A partir de los tipos de datos que vimos antes, se pueden construir objetos más complejos.

3.4.1 Matriz (`matrix`)

Colección de vectores de *igual longitud y mismo tipo de datos*. Se crea con la función `matrix()`, o combinando filas o columnas de igual longitud con `rbind()` o `cbind()`.

Por ejemplo la matriz:

$$\mathbf{M} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix}$$

en **R** se representa así:

```
M <- matrix(c(1, 2, 3, 4, 5, 6), ncol = 2)
M
```

```
     [,1] [,2]
[1,]    1    4
[2,]    2    5
[3,]    3    6
```

Se puede indexar usando `[n, p]` donde `n` es el numero de fila y `p` numero de columna. Por ejemplo para obtener el elemento m_{12}

```
M[1,2]
```

```
[1] 4
```

O todos los elementos de la columna 2

```
M[, 2]
```

```
[1] 4 5 6
```

3.4.2 Listas (`list`)

Es una generalización de los vectores ya que *los elementos pueden ser de igual o diferente tipo de datos*

```r
lst <- list(23, "hola", TRUE)
lst
```

```
[[1]]
[1] 23

[[2]]
[1] "hola"

[[3]]
[1] TRUE
```

Se pueden indexar usando `[[ ]]`

```r
# El segundo elemento de l
lst[[2]]
```

```
[1] "hola"
```

Cada elemento a su vez puede ser cualquier objeto de los vistos anteriormente.

3.4.3 Hoja de datos (`data.frame`)

Similares a las matrices pero cada columna puede ser de un tipo de dato diferente. Útil para guardar datos donde cada fila es un caso y cada columna una variable.

Supongamos que tenemos la tabla de datos:

Lote	Variedad	Rendimiento
1	Escorpion	34
2	Escorpion	36
3	Yarara	40
4	Baguette11	28
5	Tijetera	31

En **R** podemos representarla así:

```r
trigo <- data.frame(
  lote = 1:5,
  variedad = c('Escorpion', 'Escorpion', 'Yarara', 'Baguette 11', 'Tijetera'),
  rendimiento = c(34, 36, 40, 28, 31)
)
trigo
```

```
  lote    variedad rendimiento
1    1   Escorpion          34
2    2   Escorpion          36
3    3      Yarara          40
4    4 Baguette 11          28
5    5    Tijetera          31
```

Al igual que las matrices, un `data.frame` se puede indexar con `[ ]`. Por ejemplo, si quisieramos El bombre de la varidedad de la fila 2

```r
trigo[2, 3]
```

```
[1] 36
```

O todos los nombres de la fila 2

```r
trigo[2, ]
```

```
  lote  variedad rendimiento
2    2 Escorpion          36
```

Tambien podemos hacer consultas más específicas: "Lotes con rendimiento mayor a 35 qq/ha"

```r
trigo[trigo$rendimiento > 35, ]
```

```
  lote  variedad rendimiento
2    2 Escorpion          36
3    3    Yarara          40
```

Las variables o columnas se pueden acceder individualmente usando o el operador `$` seguido dle nombre de la columna o `[, "nombre"]`, o `[, posicion]`. Ejemplo: extraer la columna `rendimiento` que es la número 3

```
trigo$rendimiento
```

```
[1] 34 36 40 28 31
```

```
trigo[, "rendimiento"]
```

```
[1] 34 36 40 28 31
```

```
trigo[, 3]
```

```
[1] 34 36 40 28 31
```

Otras estructuras

Las estructura listadas arriba son nativas de **R**. Los paquetes o complementos pueden agregar nuevas estructuras o redifinar las existentes.

ACTIVIDAD

1. Unir los 2 vectores de la actividad anterior usando la función `data.frame` para crear un marco de datos llamado `info` con 2 columnas y 4 filas. Llame a la primera columna '`color` y a la segunda `peso`.
2. Ver la estructura de datos en la consola.
3. Mostrar solo la fila 3 en la consola
4. Mostrar solo la columna 1 en la consola
5. Mostrar el elemento de datos en la fila 4, columna 1

4 Paquetes de R

En esta sección vamos a aprender como extender las funcionalidades de **R** mediante la instalación y utilización de paquetes o *packages*

4.1 ¿Qué son los paquetes?

R viene con un conjunto de librerías mínimo denominado `core` que permite realizar una amplia varidedad de análisis y operaciones con los datos. La comunidad que desarrolla **R** provee un repositorio de librerías o paquetes complementarios (`packages`) que expanden notablemente las funcionalidades de **R**.

Los paquetes se deben *instalar* primero usando la función `install.packages()` por única vez y en cada sesión se deben *cargar* con `library()`. La siguiente figura resume el proceso:

Images sourced from https://www.wikihow.com/Change-a-Light-Bulb

Suponiendo que queremos instalar el paquete `foo`, se debe ejecutar por única vez:

```
install.packages("foo")
```

Luego, para acceder a todas las funciones que aporta `foo`, en cada sesión de trabajo ejecutar hay que ejecutar:

```
library("foo")
```

Alternativamente, si una vez instalado el paquete `foo` queremos usar la función `bar()` pero sin cargar el resto del paquete, entonces:

```
foo::bar(...)
```

El manejo de paquetes se puede simplificar enormemente con el paquete `pacman`. Entre otras funciones ofrece la función `p_load()` que carga los paquetes y si no están instalados los instala previamente.

Para instalar `pacman` por primera vez correr el siguiente comando:

```
# Instalar por unica vez
install.packages("pacman")
```

Luego, cuando necesitemos podemos ejecutar `pacman::p_load()`. Por ejemplo, si queremos cargar el paquete `moments`

```
pacman::p_load(moments)
```

ACTIVIDAD

1. Instalar el paquete `pacman` usando `install.packages()`
2. Cargar/Instalar el paquete `tidyverse` usando `pacman::p_load()`

5 Importar datos en R

Un aspecto importante para cualquier análisis de datos es acceder a los **datos**!

Los datos pueden estar almacenados en diversos formatos: archivos de texto (`*.txt`, `*.dat`, etc), texto separado por comas (`*.csv`), planillas de cálculos (`*.xls` o `*.xlsx`), etc.

En este curso vamos a trabajar con archivos que ya se encuentran en planillas de cálculo tipo Excel o archivos de texto plano.

5.1 Función nativa para importar datos

R viene la función `read.table()` y derivados, que permiten leer datos desde formatos tipo `texto plano` (`plain text format`). El más popular entre estos es `*.csv`. Este formato asume que los datos están en formato de tabla o *rectangular* (e.g. variables en columnas y observaciones en filas) y devuelve un `data.frame`. En ?read.table se detallan todos los argumentos, los más importantes son:

- `file` para indicar el nombre o ruta al archivo
- `header` para indicar si las columnas tienene encabezados que deben ser usados como nombre de las variables.
- `sep` para indicar el separador de columnas
- `dec` para indicar el simbolo decimal

Dependiendo de las combinaciones de estos 3 argumentos hay variantes (`read.csv()`, `read.csv2()`, `read.delim()`, `read.delim2()`) que son atajos de 'read.table()" (ver ayuda).

Mediante algun editor de textos (puede ser dentro de **RStudio**) conviene abrir el archivo y examinarlo para determinar:

- Tiene encabezados?
- Cómo están separadas las columnas?
- Cuál es el símbolo del decimal?

Supongamos que tenemos el archivo de texto `prueba.csv`, las alternativas podrían ser:

```
# Con encabezados, separado por tabulaciones y el decimal es el punto
prueba <- read.table("prueba.csv", header = T, sep = "\t", dec = ".")

# Con encabezados, separado por tabulaciones y coma como decimal
prueba <- read.table("prueba.csv", header = T, sep = "\t", dec = ",")

# Con encabezados, separado comas y punto como decimal
prueba <- read.table("prueba.csv", header = T, sep = ",", dec = ".")

# Con encabezados, separado punto y coma, y con coma como punto decimal
prueba <- read.table("prueba.csv", header = T, sep = ";", dec = ",")
```

En el caso que el archivo `prueba.csv` esté en otro directorio o ubicación que no sea el proyecto o `getwd()` hay que indicar la ruta completa al archivo.

Una vez importados los datos es conveniente verificar como han sido leidos en el **R**. Una alternativa es *imprimirlo* escribiendo el nombre del objeto directamente en la consola.

```
prueba
```

Otra alternativa es utilizar la función `View()` que muestra la tabla de datos en un formato de planilla interactiva de solo lectura.

```
View(prueba)
```

Si bien podemos inferir que tipo de datos se leyeron, una alternativa mejor es mirar la estructura con la función `str()`.

```
str(prueba)
```

ACTIVIDAD

1. Abrir un documento de texto en **RStudio**
2. Retomando el ejemplo del set de datos de trigo, crear un archivo separado por comas con los siguientes datos

```
Lote,Variedad,Rendimiento
1,Escorpion,34
2,Escorpion,36
3,Yarara,40
```

```
4,Baguette11,28
5,Tijetera,31
```

3. Guardar el archivo como `prueba_trigo.csv`.
4. Leer el set de datos dentro de **R** usando la función `read.table()` o alguna de sus variantes.
5. Verificar la importacion de los datos.

5.2 Paquetes para importar datos

Existen paquetes específicos que permiten leer virtualmente cualquier formato de archivos.

5.2.1 `readr`

Si bien la función `read.table()` y derivadas permiten leer datos *rectangulares* en formato texto, el paquete `readr` link provee una implementación más moderna (y rápidas) de estas funciones. Las funciones se llaman igual que las nativas pero se reemplaza `.` por `_` en el nombre. Ejemplo: `read_table()`

Este paquete ya está integrado a `tidyverse`. Para leer el set de datos que creamos en la actividad anterior:

```
pacman::p_load(tidyverse)
prueba_trigo <- read_csv("datasets/prueba_trigo.csv")
```

```
Rows: 5 Columns: 3
-- Column specification --------------------------------------------------------
Delimiter: ","
chr (1): Variedad
dbl (2): Lote, Rendimiento

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
prueba_trigo
```

```
# A tibble: 5 x 3
   Lote Variedad   Rendimiento
  <dbl> <chr>            <dbl>
1     1 Escorpion           34
2     2 Escorpion           36
3     3 Yarara              40
4     4 Baguette11          28
5     5 Tijetera            31
```

A diferencia de la función nativa, las funciones de `readr` devuelven un objeto llamado `tibble` que es una especie de `data.frame` pero con algunas propiedades extra.

5.2.2 `rio`

A diferencia de `readr` que es una reimplementación de funciones de **R**, hay un paquete llamado `rio` link que es una especie de *metapaquete* y permite simplificar la *importación*, *exportación*, y *conversión* de formatos en una sintaxis unificada.

Este paquete trabaja con una mayor variedad de formatos y, basado en la extensión del archivo, busca la función y/o paquete apropiado para leer o guardar los datos. En el caso de ser necesario, se pueden pasar argumentos a las funciones.

Retomando el ejemplo de trigo, podemos leer los datos con la función `import()`

```
pacman::p_load(rio)
prueba_trigo <- import("datasets/prueba_trigo.csv")
prueba_trigo
```

```
  Lote   Variedad Rendimiento
1    1  Escorpion          34
2    2  Escorpion          36
3    3     Yarara          40
4    4 Baguette11          28
5    5   Tijetera          31
```

A diferencia de `readr` siempre devuelve un `data.frame`. Si queremos que devuelva un `tibble` podemos usar el argumento `setclass`

```
prueba_trigo <- import("datasets/prueba_trigo.csv", setclass = "tibble")
prueba_trigo
```

```
# A tibble: 5 x 3
   Lote Variedad   Rendimiento
  <int> <chr>            <int>
1     1 Escorpion           34
2     2 Escorpion           36
3     3 Yarara              40
4     4 Baguette11          28
5     5 Tijetera            31
```

5.3 Formas de importar datos

A continuación vamos a detallar dos formas de abrir el archivo que contiene datos meteorológicos de la ciudad de Urbana (Illinois).

5.3.1 Desde la consola (recomendado)

Una vez que descargamos el archivo datos en la carpeta `datasets` dentro de nuestro directorio de trabajo o proyecto podemos leerlo en **R** usando la función `import()` del paquete `rio`. Esta función se encargará de llamar la función necesaria para leer el archivo que le suministremos.

```
urbana <- import("datasets/urbana_weather.xlsx", setclass = "tibble")
urbana
```

```
# A tibble: 240 x 4
    YEAR month precip  temp
   <dbl> <chr>  <dbl> <dbl>
 1  2000 Jan     1.54  25.6
 2  2001 Jan     1.32  25.4
 3  2002 Jan     2.81  34
 4  2003 Jan     0.79  21.1
 5  2004 Jan     2.18  24
 6  2005 Jan     6.2   27.8
 7  2006 Jan     1.78  37.8
 8  2007 Jan     3.03  29.7
 9  2008 Jan     2.31  26.2
10  2009 Jan     0.68  18.8
# i 230 more rows
```

Si sólo estuvieramos ineresados en el rango `A1:C5` (primeros 4 registros de las 3 primeras columnas), podríamos usar:

```r
urbana2 <- import(file = "datasets/urbana_weather.xlsx", range = "A1:C5")
urbana2
```

```
  YEAR month precip
1 2000   Jan   1.54
2 2001   Jan   1.32
3 2002   Jan   2.81
4 2003   Jan   0.79
```

5.3.2 Desde el importador de datos de RStudio

RStudio cuenta con un asistente de importación de datos (`File > Import Dataset`) que brinda interfase a varias funciones especializadas en la importación de datos de paquetes específicos como `readr`, `readxl`, etc.

En el menú `File > Import Dataset` o bien el ícono del panel `Environment` despliega una lista con disitintas opciones de importación: nos interesa `From Excel (readxl)...`

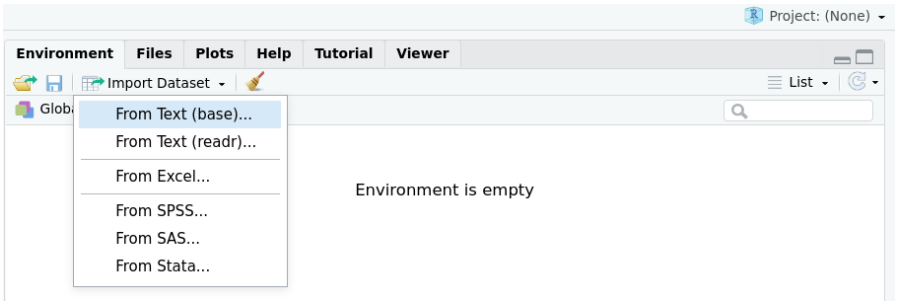

Figura 5.1: Importador de datos

Este menú tiene cuatro paneles:

1. Una barra de direccion para indicar la ruta al archivo o URL.
2. Una vista previa del contenido del archivo
3. Opciones de importación: aquí se puede especificar el nombre del objeto que se creará dentro de **R** (`Name`), la cantidad de lineas a leer, el número de la hoja, el rango de celdas, líneas a saltear (`skip`) y el identificador de datos `NA`.
4. Vista previa del código. En esta parte se puede visualizar como se construye el comando que se ejecturará al clickear en `Import`.

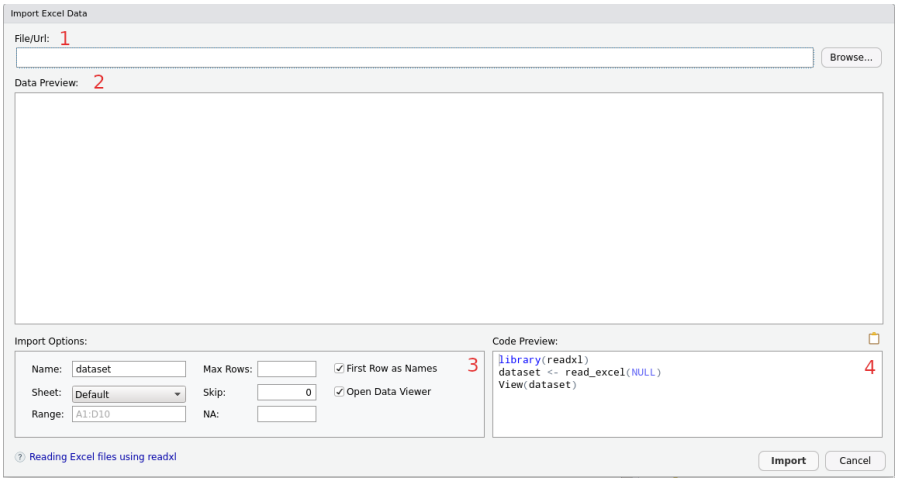

Figura 5.2: Importador de datos

> **Aclaración**
>
> Si bien esta alternativa es intuitiva y amigable, no es reproducible a menos que el código generado por este asistente sea incluido en el script para futuras sesiones.

5.3.3 Desde el portapapeles

Una alternativa conveniente para acceder rápidamente a los datos es usando el portapapeles. Suponiendo que los datos estan en una hoja de cálculos:

1. Seleccionar el rango de celdas `A1:C5` que nos interesa incluyendo los encabezados
2. Copiar en el porta papeles (CTRL + C)
3. Luego en R

```
urbana3 <- read.table("clipboard")
```

> **Aclaración**
>
> Si bien esta alternativa es rápida, al no ser reproducible (no hay forma de plasmarla en el script para futuras sesiones), **no es recomendable** salvo para una exploración rápida.

6 Manipulando datos con `dplyr` y `tidyr`

Luego de importar los datos **R** es necesario explorarlos y, dependiendo de su organización o el análisis que querramos realizar, hay que realizar algun tipo transformación, resumen, o consultas.

`dplyr` y `tidyr` son dos paquetes de **R** muy potentes para la exploración, transformación y resumen de datos en formato de tabla con filas (observaciones) y columnas (variables). Ambos son componentes de un meta-package `tidyverse` desarrollados por Hadley Wickham

Ambos paquetes tienen un conjunto de funciones (o *verbos*) que realizan operaciones comunes para el manejo de datos tales como: filtrar filas, seleccionar columnas, re-ordenar filas, agregar o transformar columnas, resumir datos. También permite agrupar los datos facilitando la estrategia *split-apply-combine*, es decir, dividir (*split*) los datos según una variable de grupo, aplicar (*apply*) alguna transformación o resumen y combinar (*combine*) las partes para presentar los resultados.

Si bien **R** base tiene funciones que realizan las mismas tareas (`split()`, `subset()`, `apply()`, `sapply()`, `lapply()`, `tapply()` and `aggregate()`), estos paquetes brindan una interface más consistente que permite trabajar de manera más fácil con `data.frame` (tabla de datos) más que con vectores.

Veamos con un ejemplo como realizar algunas operaciones con estos paquetes. Para esto vamos a usar el set de datos . Suponiendo que ya está descargado en la carpeta de trabajo o proyecto.

```
pacman::p_load(rio)
novillos <- import("datasets/pesada_novillos.xlsx", setclass = "tibble")
novillos
```

```
# A tibble: 1,842 x 13
   IDV   Tropa Procedencia Fecha_Ingreso Peso_inicial Peso_anterior GPV_anterior
   <chr> <dbl> <chr>       <chr>                <dbl>         <dbl>        <dbl>
 1 GH73~     2 <NA>        42939                  188           306           51
 2 IA67~     2 La Rosita   42940                  232           290            2
 3 PO15~     2 La Alameda  42939                  204           290           33
 4 GH73~     2 <NA>        42940                  204           303           27
 5 SZ20~     2 La Alameda  42940                  202           300           30
 6 IA67~     2 La Rosita   42940                  234           333           38
```

```
 7 PO15~     2 Los Corral~ 42938                214          287          14
 8 PO15~     2 Los Corral~ 42939                184          315          37
 9 NS50~     2 La Rosita   42938                234          288           0
10 QX67~     2 La Alameda  42940                206          262           2
# i 1,832 more rows
# i 6 more variables: GDM_anterior <dbl>, Fecha <chr>, Hora <chr>, Peso <dbl>,
#   Días <dbl>, Días_total <dbl>
```

6.1 ¿Cómo instalar `dplyr` y `tidyr`?

Para acceder a estos paquetes instalarlos/cargarlos individualmente:

```
pacman::p_load(dplyr, tidyr)
```

O bien con otros paquete de la familia `tidyverse`

```
pacman::p_load(tidyverse)
```

R va a avisarnos en la consola que esta enmascarando (reemplazando) algunas funciones que ya estaban en el entorno, o bien el paquete nos devuelve algun mensaje. A menos que diga `Error ...`, eso está bien.

6.2 Verbos importantes de `dplyr` para recordar

Toda la estrategia de trabajo con datos de `dplyr` se basa en 6 *verbos*:

verbo	descripción
`select()`	selecciona columnas (variables)
`filter()`	filtra o selecciona las filas (observaciones)
`arrange()`	re-ordena las filas
`mutate()`	crea nuevas columnas o modifica las preexistentes
`summarise()`	resumen los valores de una variable
`group_by()`	permite aplicar los verbos anteriores en subgrupos (*split-apply-combine*)

En la mayoría de los casos la sintaxis es:

`function(que_datos, que_hacer_con_los_datos)`

donde `que_datos` es el nombre del set de datos (un `data.frame`) y `que_hacer_con_los_datos` indicar que operación, condicion, transformacion, etc. aplicar a las filas y columnas.

Veamos unos ejemplos

6.3 Seleccionando variables

Para seleccionar columnas (variables) de interes usamos `select()`. La selección se puede hacer por nombre de la columna (con o sin comillas) o indicando su posición.

Las columnas del set de datos de ejemplo se denominan:

```
names(novillos)
```

```
 [1] "IDV"           "Tropa"         "Procedencia"   "Fecha_Ingreso"
 [5] "Peso_inicial"  "Peso_anterior" "GPV_anterior"  "GDM_anterior"
 [9] "Fecha"         "Hora"          "Peso"          "Días"
[13] "Días_total"
```

Si quisieramos seleccionar las columnas `Procedencia`, `Peso_inicial`, `Peso_anterior` y `Peso`, podríamos ejectuar:

```
select(novillos, Procedencia, Peso_inicial, Peso_anterior, Peso)
```

```
# A tibble: 1,842 x 4
   Procedencia    Peso_inicial Peso_anterior  Peso
   <chr>                 <dbl>         <dbl> <dbl>
 1 <NA>                    188           306   398
 2 La Rosita               232           290   387
 3 La Alameda              204           290   386
 4 <NA>                    204           303   382
 5 La Alameda              202           300   382
 6 La Rosita               234           333   374
 7 Los Corralitos          214           287   371
 8 Los Corralitos          184           315   369
 9 La Rosita               234           288   365
10 La Alameda              206           262   365
# i 1,832 more rows
```

El resultado es un nuevo `data.frame` o `tibble` que sólo contiene las 4 columnas seleccionadas. Si quisieramos guardar este resultado aparte.

```r
pesos <- select(novillos, Procedencia, Peso_inicial, Peso_anterior, Peso)
pesos
```

```
# A tibble: 1,842 x 4
   Procedencia    Peso_inicial Peso_anterior  Peso
   <chr>                 <dbl>         <dbl> <dbl>
 1 <NA>                    188           306   398
 2 La Rosita               232           290   387
 3 La Alameda              204           290   386
 4 <NA>                    204           303   382
 5 La Alameda              202           300   382
 6 La Rosita               234           333   374
 7 Los Corralitos          214           287   371
 8 Los Corralitos          184           315   369
 9 La Rosita               234           288   365
10 La Alameda              206           262   365
# i 1,832 more rows
```

Cuando se imprime en la consola, es lo mismo que usar `print()` la cual por defecto muestra las 10 primeras observaciones y la cantidad de columnas que entran en la pantalla. Aquellas columnas que no entran son indicadas al pie.

Si uno desea ver más registros se puede usar el argumento `n =` de `print()`

```r
print(pesos, n = 15)
```

```
# A tibble: 1,842 x 4
   Procedencia    Peso_inicial Peso_anterior  Peso
   <chr>                 <dbl>         <dbl> <dbl>
 1 <NA>                    188           306   398
 2 La Rosita               232           290   387
 3 La Alameda              204           290   386
 4 <NA>                    204           303   382
 5 La Alameda              202           300   382
 6 La Rosita               234           333   374
 7 Los Corralitos          214           287   371
 8 Los Corralitos          184           315   369
 9 La Rosita               234           288   365
10 La Alameda              206           262   365
11 La Alameda              216           308   362
12 La Rosita               240           298   362
```

```
13 La Alameda              164           285   361
14 La Rosita               216           308   361
15 La Alameda              176           289   361
# i 1,827 more rows
```

Con `n = "all"` se imprimen todas (no se muestra por razones obvias)

El orden en que aparecen las variables en el resultado es el orden que se utilizó al seleccionarlas.

```
select(novillos, Procedencia, Peso, Peso_inicial, Peso_anterior)
```

```
# A tibble: 1,842 x 4
   Procedencia     Peso Peso_inicial Peso_anterior
   <chr>          <dbl>        <dbl>         <dbl>
 1 <NA>             398          188           306
 2 La Rosita        387          232           290
 3 La Alameda       386          204           290
 4 <NA>             382          204           303
 5 La Alameda       382          202           300
 6 La Rosita        374          234           333
 7 Los Corralitos   371          214           287
 8 Los Corralitos   369          184           315
 9 La Rosita        365          234           288
10 La Alameda       365          206           262
# i 1,832 more rows
```

También se puede usar los comandos `starts_with()`, `ends_with()`, `contains()`, etc (ver `?select_helpers`) para más opciones). Para elegir varias columnas que tienen un patrón sin tener que tipear todos los nombres.

```
select(novillos, starts_with("P"))
```

```
# A tibble: 1,842 x 4
   Procedencia    Peso_inicial Peso_anterior  Peso
   <chr>                 <dbl>         <dbl> <dbl>
 1 <NA>                    188           306   398
 2 La Rosita               232           290   387
 3 La Alameda              204           290   386
 4 <NA>                    204           303   382
 5 La Alameda              202           300   382
```

```
 6 La Rosita               234           333   374
 7 Los Corralitos          214           287   371
 8 Los Corralitos          184           315   369
 9 La Rosita               234           288   365
10 La Alameda              206           262   365
# i 1,832 more rows
```

Para omitir algunas columnas en la seleccion se puede usar el `-` antes del nombre. Por ejemplo, omitir la columna `IDV` y todas las que empiezan con `P`.

```
  select(novillos, -IDV, -starts_with("P"))
```

```
# A tibble: 1,842 x 8
   Tropa Fecha_Ingreso GPV_anterior GDM_anterior Fecha Hora      Días Días_total
   <dbl> <chr>                <dbl>        <dbl> <chr> <chr>    <dbl>      <dbl>
 1     2 42939                   51         1.04 43138 0.80824~    76        293
 2     2 42940                    2         0.04 43138 0.46511~    76        293
 3     2 42939                   33         0.67 43138 0.34270~    76        302
 4     2 42940                   27         0.52 43138 0.34829~    75        293
 5     2 42940                   30         0.58 43138 0.80134~    75        304
 6     2 42940                   38         0.73 43138 0.34018~    75        295
 7     2 42938                   14         0.27 43138 0.32917~    75        303
 8     2 42939                   37         0.76 43138 0.33152~    76        303
 9     2 42938                    0         0    43138 0.37302~    76        302
10     2 42940                    2         0.08 43143 0.46458~   132        306
# i 1,832 more rows
```

6.4 Seleccionando observaciones

Otra tarea muy frecuente es seleccionar casos o observaciones que cumplan con alguna condición. Esto se lleva a cabo con `filter()`. Se pueden usar los operadores *booleanos* `==`, `>`, `<`, `>=`, `<=`, `!=`, `%in%`) para crear pruebas o condiciones lógicas.

Por ejemplo, para seleccionar los novillos de `Los Corralitos`:

```
  filter(novillos, Procedencia == 'Los Corralitos')
```

```
# A tibble: 57 x 13
   IDV   Tropa Procedencia Fecha_Ingreso Peso_inicial Peso_anterior GPV_anterior
   <chr> <dbl> <chr>       <chr>                <dbl>         <dbl>        <dbl>
```

```
 1 PO15~     2 Los Corral~ 42938                214          287           14
 2 PO15~     2 Los Corral~ 42939                184          315           37
 3 PO15~     2 Los Corral~ 42937                168          266           22
 4 PO15~     2 Los Corral~ 42937                182          281           31
 5 PO15~     2 Los Corral~ 42938                200          276           20
 6 PO15~     2 Los Corral~ 42937                162          231           19
 7 PO15~     2 Los Corral~ 42937                166          240           26
 8 PO15~     2 Los Corral~ 42942                162          232           28
 9 PO15~     2 Los Corral~ 42939                200          258           26
10 PO15~     2 Los Corral~ 42940                170          252           37
# i 47 more rows
# i 6 more variables: GDM_anterior <dbl>, Fecha <chr>, Hora <chr>, Peso <dbl>,
#   Días <dbl>, Días_total <dbl>
```

Para crear un subconjunto podemos asignarlo y crear un nuevo set de datos.

```
corralitos <- filter(novillos, Procedencia == 'Los Corralitos')
```

La selección se puede hacer por más de una condición. Por ejemplo, seleccionar los de `Los Corralitos` que pesen más de 300 kg:

```
filter(novillos, Procedencia == 'Los Corralitos', Peso > 300)
```

```
# A tibble: 29 x 13
   IDV   Tropa Procedencia Fecha_Ingreso Peso_inicial Peso_anterior GPV_anterior
   <chr> <dbl> <chr>       <chr>                <dbl>         <dbl>        <dbl>
 1 PO15~     2 Los Corral~ 42938                  214           287           14
 2 PO15~     2 Los Corral~ 42939                  184           315           37
 3 PO15~     2 Los Corral~ 42937                  168           266           22
 4 PO15~     2 Los Corral~ 42937                  182           281           31
 5 PO15~     2 Los Corral~ 42938                  200           276           20
 6 PO15~     2 Los Corral~ 42937                  162           231           19
 7 PO15~     2 Los Corral~ 42937                  166           240           26
 8 PO15~     2 Los Corral~ 42942                  162           232           28
 9 PO15~     1 Los Corral~ 23/7/2017              252           343           31
10 PO15~     1 Los Corral~ 22/7/2017              234           338           23
# i 19 more rows
# i 6 more variables: GDM_anterior <dbl>, Fecha <chr>, Hora <chr>, Peso <dbl>,
#   Días <dbl>, Días_total <dbl>
```

`filter()` asume que cada condicion se debe cumplir en simultaneo para que la observación sea seleccionada. Esto equivale a utilizar el operador `&` (Y). En caso de querer seleccionar aquellos

registros que cumple una u otra condicion se usa el operador `|` (*O*). Poniendo `!` delante de la condicion se invierte la selección.

Por ejemplo, para obtener novillos que son de `Los Corralitos` **O** pesan más de 300 kg.

```
filter(novillos, Procedencia == 'Los Corralitos' | Peso > 300)
```

```
# A tibble: 841 x 13
   IDV   Tropa Procedencia Fecha_Ingreso Peso_inicial Peso_anterior GPV_anterior
   <chr> <dbl> <chr>       <chr>                <dbl>         <dbl>        <dbl>
 1 GH73~     2 <NA>        42939                  188           306           51
 2 IA67~     2 La Rosita   42940                  232           290            2
 3 PO15~     2 La Alameda  42939                  204           290           33
 4 GH73~     2 <NA>        42940                  204           303           27
 5 SZ20~     2 La Alameda  42940                  202           300           30
 6 IA67~     2 La Rosita   42940                  234           333           38
 7 PO15~     2 Los Corral~ 42938                  214           287           14
 8 PO15~     2 Los Corral~ 42939                  184           315           37
 9 NS50~     2 La Rosita   42938                  234           288            0
10 QX67~     2 La Alameda  42940                  206           262            2
# i 831 more rows
# i 6 more variables: GDM_anterior <dbl>, Fecha <chr>, Hora <chr>, Peso <dbl>,
#   Días <dbl>, Días_total <dbl>
```

6.5 Encadenando operaciones (operador %>%)

El operador `%>%` permite encadenar operaciones sucesivas para evitar tener que crear tablas intermedias o anidar funciones. El operador y se le de izquierda a derecha y se puede traducir como *luego*.

Por ejemplo, reportar los `IDV` y `Peso` de los novillos con más de 250 kg. Esto implicaría seleccionar las columnas de interés creando tablas intermedias y *luego* filtrar la tabla o vice versa.

Creando tablas intermedias

```
novillos2 <- select(novillos, IDV, Peso)
novillos2
```

```
# A tibble: 1,842 x 2
   IDV        Peso
```

```
   <chr>     <dbl>
 1 GH738B371   398
 2 IA671B298   387
 3 PO150A818   386
 4 GH738B340   382
 5 SZ208H766   382
 6 IA671B133   374
 7 PO150A532   371
 8 PO150A563   369
 9 NS509H071   365
10 QX678K546   365
# i 1,832 more rows
```

```
novillos2 <- filter(novillos2, Peso > 250)
novillos2
```

```
# A tibble: 1,682 x 2
   IDV        Peso
   <chr>     <dbl>
 1 GH738B371   398
 2 IA671B298   387
 3 PO150A818   386
 4 GH738B340   382
 5 SZ208H766   382
 6 IA671B133   374
 7 PO150A532   371
 8 PO150A563   369
 9 NS509H071   365
10 QX678K546   365
# i 1,672 more rows
```

Anidando las funciones:

```
filter(select(novillos, IDV, Peso), Peso > 250)
```

```
# A tibble: 1,682 x 2
   IDV        Peso
   <chr>     <dbl>
 1 GH738B371   398
 2 IA671B298   387
```

```
 3 PO150A818   386
 4 GH738B340   382
 5 SZ208H766   382
 6 IA671B133   374
 7 PO150A532   371
 8 PO150A563   369
 9 NS509H071   365
10 QX678K546   365
# i 1,672 more rows
```

Una opción más clara para leer y eficiente es usando `%>%`

```
  novillos %>%
    select(IDV, Peso) %>%
    filter(Peso >  250)
```

```
# A tibble: 1,682 x 2
   IDV        Peso
   <chr>     <dbl>
 1 GH738B371   398
 2 IA671B298   387
 3 PO150A818   386
 4 GH738B340   382
 5 SZ208H766   382
 6 IA671B133   374
 7 PO150A532   371
 8 PO150A563   369
 9 NS509H071   365
10 QX678K546   365
# i 1,672 more rows
```

Con `%>%` se puede omitir el nombre de la tabla sobre la que se está trabajando (bonus: menos tipeo).

La última opción se lee: _tomar la tabla `novillos`, **luego** seleccionar las columnas `IDV` y `Peso`, **luego** filtrar los novillos con pesos mayores a 250 kg.

6.6 Ordenar las filas

Para ordenar según algún criterio aplicado a las columnas se usa `arrange()`. Por ejemplo, continuar con lo anterior pero mostrar ordenadospor peso.

```r
  novillos %>%
    select(IDV, Peso) %>%
    filter(Peso >  250) %>%
    arrange(Peso)
```

```
# A tibble: 1,682 x 2
   IDV        Peso
   <chr>     <dbl>
 1 ME367A534   251
 2 SZ208H833   251
 3 NS545A388   251
 4 ME367A545   251
 5 NS509H010   251
 6 PO150A777   251
 7 PO150A752   251
 8 SZ208H765   252
 9 NS545A455   252
10 SZ208I511   252
# i 1,672 more rows
```

Con `decs(variable)` se ordena de mayor a menor

```r
  novillos %>%
    select(IDV, Peso) %>%
    filter(Peso >  250) %>%
    arrange(desc(Peso))
```

```
# A tibble: 1,682 x 2
   IDV        Peso
   <chr>     <dbl>
 1 GH738B371   398
 2 IA671B276   397
 3 IA671B298   387
 4 PO150A818   386
 5 GH738B340   382
 6 SZ208H766   382
 7 IA671B133   374
 8 PO150A532   371
 9 PO150A866   371
10 PO150A563   369
# i 1,672 more rows
```

6.7 Crear o transformar columnas

Para crear nuevas columnas aplicando funciones a otras, o bien para transformar columnas se usa `mutate()`. Se pueden modificar más de una columna a la vez. Por ejemplo, suponiendo que interesa obtener la diferencia de peso desde el inicio del ciclo:

```
dif_peso = Peso - Peso_inicial
```

```
novillos %>%
  mutate(dif_peso = Peso - Peso_inicial) %>%
  select(Peso, Peso_inicial, dif_peso)  # para que se vea mejor el resultado
```

```
# A tibble: 1,842 x 3
    Peso Peso_inicial dif_peso
   <dbl>        <dbl>    <dbl>
 1   398          188      210
 2   387          232      155
 3   386          204      182
 4   382          204      178
 5   382          202      180
 6   374          234      140
 7   371          214      157
 8   369          184      185
 9   365          234      131
10   365          206      159
# i 1,832 more rows
```

Esto no cambia el set de datos `novillos` ya que no se lo asignó a ningun objeto. Para sobreescribir o actualiza el set de datos `novillos` hay que asignarlo al mismo objeto.

```
novillos <- novillos %>%
  mutate(dif_peso = Peso - Peso_inicial)
```

Aclaración: Si se hubiese usado `select()` el set de datos novillos solamente contendría las columnas seleccionadas.

6.7.1 Resumir datos

Mediante `summarise()` se pueden aplicar funciones para resumir en un solo valor los valores de las columnas. Las funciones a aplicar deben devolver un único valor, por ejemplo `mean()`. Si usamos `summary()` esto devolverá 6 valores y dará error.

```r
novillos %>%
  summarise(
    media = mean(Peso),
    sd = sd(Peso),
    n = n(),
    suma = sum(Peso),
    procedencias = n_distinct(Procedencia)
  )
```

```
# A tibble: 1 x 5
  media    sd     n   suma procedencias
  <dbl> <dbl> <int>  <dbl>        <int>
1  294.  33.1  1842 541693            4
```

Nuevamente estos resultados pueden asignarse a otro objeto o bien encadenarse con otras operaciones.

6.7.2 Agrupar (último pero no menos importante)

El verbo `group_by()` es muy útil para aplicar operaciones en subgrupos y presentar todo junto (*split-apply-combine*). Lo que hace es indicar que en el `data.frame` hay una o más variables que conforman los grupos. Luego cada operación se aplica a esos subgrupos.

Ejemplo: calcular media, desvio, n y suma para cada procedencia, descartando los que tienen `NA` en `Procedencia`

```r
novillos %>%
  filter(!is.na(Procedencia)) %>%
  group_by(Procedencia) %>%
  summarise(
    media = mean(Peso),
    sd = sd(Peso),
    n = n(),
    suma = sum(Peso)
  )
```

```
# A tibble: 3 x 5
  Procedencia    media    sd     n   suma
  <chr>          <dbl> <dbl> <int>  <dbl>
1 La Alameda      297.  28.3   638 189236
```

```
2 La Rosita       296.  31.2   849 250951
3 Los Corralitos  300.  33.3    57  17085
```

6.8 Tablas pivot

Al igual que `dplyr`, las funciones de `tidyr` son compatibles con el operador `%>%`.

Las funciones más importantes de este paquete son `pivot_longer()` y `pivot_wider()`, las cuales permiten de manera facil convertir tablas apaisadas en tablas longitudinales los nombres de algunas variables pasan a ser los valores de una nueva variable y los valores se combinan en una nueva variable.

Formato *wide*

```
x    y
1    a
2    b
3    c
```

Formato *long*

```
Variable Valor
x        1
x        2
x        3
y        a
y        b
y        c
```

Veamos un ejemplo: las variables `Peso`, `Peso_inicial` y `Peso_anterior` pueden verse como la variable `Peso` medida en 3 momentos. Podríamos generar una tabla longitudinal combinando estas 3 variables en una sola y creando otra que indique el momento de medición.

```
pesos_long <- novillos %>%
  pivot_longer(cols = contains("Peso"), names_to = "momento", values_to = "peso") %>%
  select(IDV, Procedencia, momento, peso)
pesos_long
```

```
# A tibble: 7,368 x 4
   IDV       Procedencia momento        peso
   <chr>     <chr>       <chr>         <dbl>
 1 GH738B371 <NA>        Peso_inicial    188
 2 GH738B371 <NA>        Peso_anterior   306
 3 GH738B371 <NA>        Peso            398
 4 GH738B371 <NA>        dif_peso        210
 5 IA671B298 La Rosita   Peso_inicial    232
 6 IA671B298 La Rosita   Peso_anterior   290
 7 IA671B298 La Rosita   Peso            387
 8 IA671B298 La Rosita   dif_peso        155
 9 PO150A818 La Alameda  Peso_inicial    204
10 PO150A818 La Alameda  Peso_anterior   290
# i 7,358 more rows
```

Como vemos, ahora tenemos una tabla que para cada novillo `IDV`, tiene los pesos en los distintos momentos no como columnas sino como valores de la variable `peso` y la columna `momento` identifica el asocia el momento en que se pesó el animal.

7 Visualización de datos con `ggplot2`

R tiene por defecto el paquete `graphics`, también conocido como *base plot system*, que provee la función genérica `plot()` para hacer gráficos simples, y otras funciones para gráficos específicos (`hist()`, `barplot()`, `boxplot()`, etc).

Usa un enfoque de *papel y lapiz* por capas donde el gráfico final es una sumatoria de capas que se agregan una a la vez sin posibilidad de modificarse luego. Generalmente es OK para gráficos simples o exploratorios. Para gráficos más complejos (con subgrupos o multipanel) requiere programar más. Una desventaja es la sintaxis poco consistente.

El paquete `ggplot2`, desarrollado por Hadley Wickham, está basado en la filosofía *Gramática de gráficos* (*grammar of graphics* , por eso `gg`). Combina los dos enfoques: *por capas* y *función*.

Uno provee los datos, indica que variables asignar a las estéticas (ejes, escalas, colores, símbolos) y las geometrías o formas que se quieren graficar y `ggplot2` se encarga del resto. Se puede ir agregando capas. Es muy potente para la exploración y visualización de datos en formato de tabla con filas (observaciones) y columnas (variables).

7.1 ¿Cómo conseguir `ggplot2`?

Para acceder a estos paquetes instalarlos/cargarlos individualmente:

```
pacman::p_load(ggplot2)
```

O bien con otros paquete de la familia `tidyverse`

```
pacman::p_load(tidyverse)
```

R va a avisarnos en la consola que esta enmascarando (reemplazando) algunas funciones que ya estaban en el entorno, o bien el paquete nos devuelve algun mensaje. A menos que diga `Error ...`, eso está bien.

7.2 Componentes del gráfico en `ggplot2`

`ggplot2` implementa una variante *por capas* de este paradigma gramática de gráficos de Leland Wilkinson (`gg` es por *grammar of graphics*). Como resultado, se crean una serie de capas que permiten describir y construir visualizaciones de manera estructurada en cuanto a representación de los elementos pero a su vez flexible para generar combinaciones nuevas.

Un gráfico se define por la combinación de capas (`layers`), escalas (`scales`), coordenadas (`coords`) y facetas (`facets`). Adicionalmente a estos componentes se pueden aplicar temas (`themes`) que permiten controlar los detalles del diseño de la visualización.

7.2.1 Layers

Los `layer` se construyen con las funciones `geom_*` y `stat_*` que veremos más adelante. Constan de 5 elementos:

- `data`, set de datos (`data.frame` o similar) que contiene la información que se desea visualizar.
- `mapping`, elementos de mapeo definidos mediante `aes()` para indicar la forma en que la las variables y observaciones van a ser representadas en la visualización mediante atributos estéticos (ejes, lineas, colores, rellenos, etc).
- `stat`, funciones estadísticas que resumen los datos aplicando funciones estadísticas, e.g. promedio, agrupamiento y conteo de observaciones, o ajuste de un modelo lineal o suavizado, etc.
- `geom`, geometrías o formas que representan lo que realmente se ve en un gráfico: puntos, líneas, polígonos, etc.
- `position`, ajuste de posición de los elementos `geoms` dentro de un layer para evitar su superposición.

Generalmente, sobre todo para gráficos simples, `data` y `mapping` se definen una vez para todo el gráfico dentro de la función `ggplot()`. En otras situaciones se hace a nivel de cada `layer`.

7.2.2 Scales

Asignan los valores del espacio de datos a valores en el espacio de los elementos estéticos (`aesthetics` o `aes`). Por ejemplo, el uso de un color, forma o tamaño de en un `geom` puede ser controlado por un atributo de los datos. Las escalas también definen las leyenda y los ejes.

7.2.3 Coordenadas

Sistema de coordendas (`coord`) que define que variables definiran el espacio del gráfico y como se representarán, e.g. coordanedas cartesianas, polares, etc.

7.2.4 Paneles (`facets`)

Es un elemento que permite especificar una o más variables para dividir el gráfico en paneles y así mostrar subgrupos de datos. Esto permite ver visualizar relaciones condicionales entre variables, e.g. `y ~ x | z`, es decir, que pasa con la variable `x` e `y` cuando cambia `z`.

7.2.5 Temas

Adicionalmente a estos componentes se pueden aplicar temas (`themes`) que permiten controlar los detalles del desieño de la visualización, tipografía, posición de algunos objetos, paleta de colores, etc. Los valores predeterminados de `ggplot2` son un buen punto de partida pero exiten opciones predefinidas que pueden modificarse para generar un tema particular. Otra fuente para consultar es el trabajo de Tufte

7.3 Primer gráfico paso a paso

```
pacman::p_load(rio)
novillos <- import("datasets/pesada_novillos.xlsx", setclass = "tibble")
novillos
```

```
# A tibble: 1,842 x 13
   IDV   Tropa Procedencia Fecha_Ingreso Peso_inicial Peso_anterior GPV_anterior
   <chr> <dbl> <chr>       <chr>                <dbl>         <dbl>        <dbl>
 1 GH73~     2 <NA>        42939                  188           306           51
 2 IA67~     2 La Rosita   42940                  232           290            2
 3 PO15~     2 La Alameda  42939                  204           290           33
 4 GH73~     2 <NA>        42940                  204           303           27
 5 SZ20~     2 La Alameda  42940                  202           300           30
 6 IA67~     2 La Rosita   42940                  234           333           38
 7 PO15~     2 Los Corral~ 42938                  214           287           14
 8 PO15~     2 Los Corral~ 42939                  184           315           37
 9 NS50~     2 La Rosita   42938                  234           288            0
10 QX67~     2 La Alameda  42940                  206           262            2
# i 1,832 more rows
```

```
# i 6 more variables: GDM_anterior <dbl>, Fecha <chr>, Hora <chr>, Peso <dbl>,
#   Días <dbl>, Días_total <dbl>
```

Veamos con un ejemplo como se combinan los componentes anteriormente vistos para realizar un gráfico simple. Para esto vamos a usar el set de datos

Nuestro primer gráfico tendrá como objetivo mostrar la relación que existe entre `Peso_anterior` y `Peso` (actual), y potencialmente ver si ésta es similar entre procedencias. Veamos paso por paso como se construye el gráfico.

Primero definimos el set de datos que usaremos:

```
ggplot(data = novillos)
```


Como vemos esto no produjo nada ya que no indicamos cuales son las variables que queremos graficar y cómo graficarlas. Nuestro `layer` solo tiene la información de `data`. Agreguemos ahora la información de `mappping` usando `aes()`. Usando el operador `+` podemos concatenarlo al comando anterior.

```
ggplot(data = novillos) +
  aes(x = Peso_inicial, y = Peso)
```

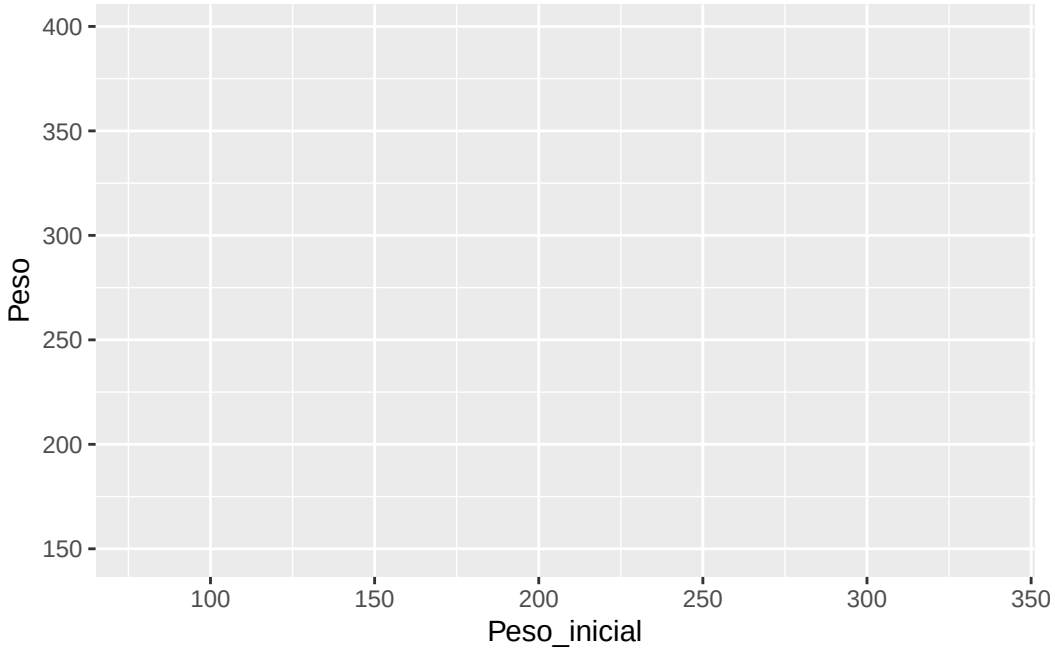

Aquí vemos que, si bien no hemos graficado nada, la información suministrada permite a `ggplot` identificar los ejes, definir el espacio de coordanadas (cartesianas por defecto) y proponer unos límites en función del rango de valores. Agreguemos ahora la geometría: en este caso tiene sentido usar `geom_point()` ya que queremos mostrar un punto por observación

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso) +
  geom_point()
```

```
Warning: Removed 32 rows containing missing values (`geom_point()`).
```

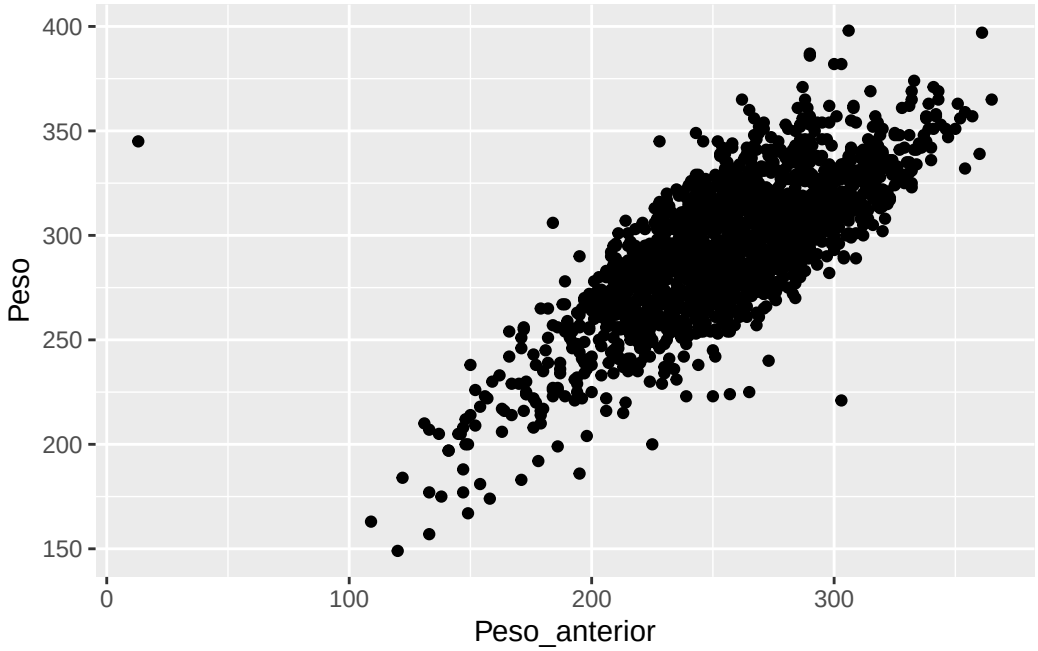

Como vemos ahora el gráfico va tomando forma. Este tipo de gráficos se llama *gráfico de dispersión* y muestra la relación entre ambas variables. Por defecto no se aplica ninguna transformación estadística lo que equivale a (`stat = "identity"`).

A este gráfico vamos a agregarle alguna función que permita resumir la relación entre ambas variables, por ejemplo un modelo de regresión. La mejor forma de representarlo sería una línea. Para eso vamos a agregar otro `layer` con `geom_line()` donde indicaremos una transformación de los datos `stat = smooth`.

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso) +
  geom_point() +
  geom_line(stat = 'smooth', method = 'lm')
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory
```

```
Warning: Removed 32 rows containing missing values (`geom_point()`).
```

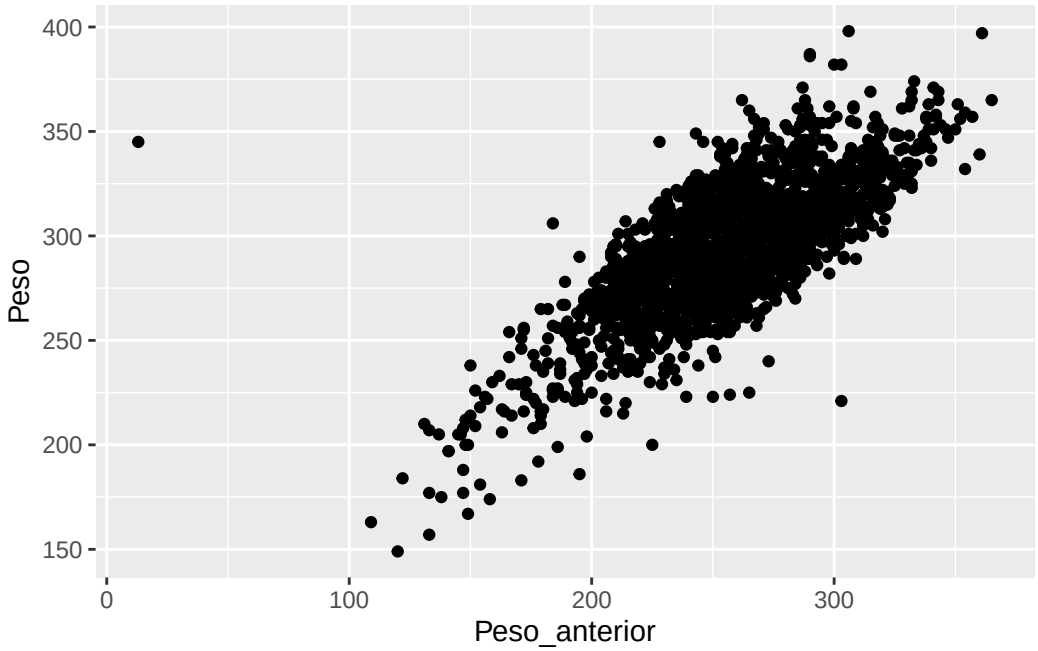

Hay una relación positiva para todo el set de datos pero puede enmascarar algun patrón por `Procedencia`. Esta información la podemos agregar con otros atributos estéticos como por ejemplo `color`:

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso, color = Procedencia) +
  geom_point() +
  geom_line(stat = 'smooth', method = 'lm')
```

```
`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).

Warning: Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory

Warning: Removed 32 rows containing missing values (`geom_point()`).
```

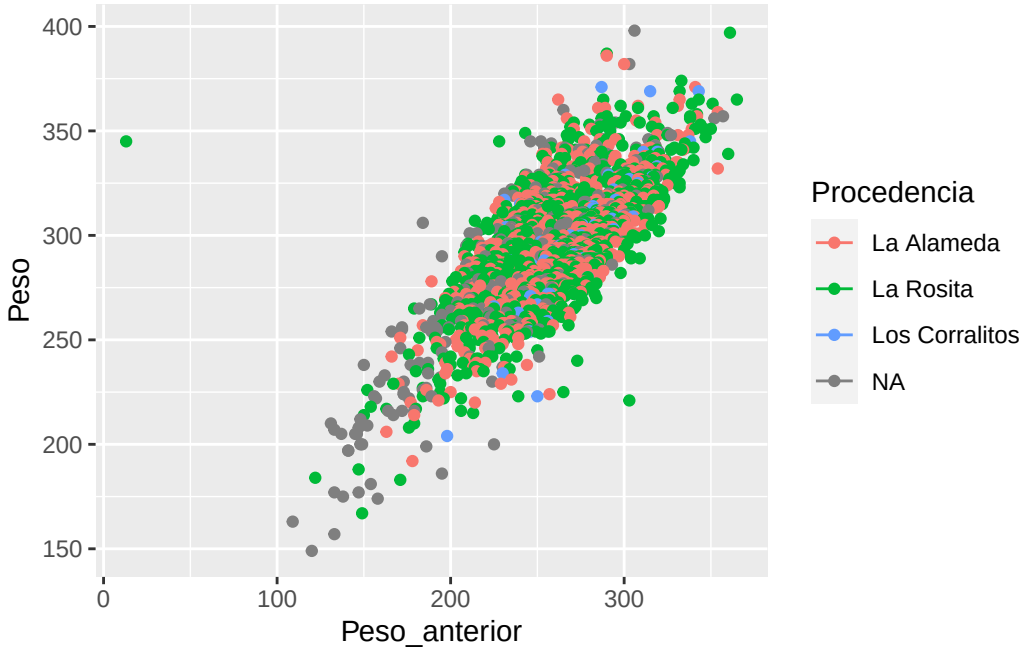

De este gráfico surge que la relación en todos los casos es positiva pero varia un poco según procedencia.

Dependiendo el tipo de `geom` tenemos distintos atributos estéticos para explorar: `color` y `alpha` (transparencia) para todos, `shape` y `size` para puntos, `linewidth` y `linetype` para lineas, y `fill` para barras, etc. Que tipo de atributo estético depende también de la naturaleza de la variable: continua o discreta. Veamos como queda mapear los valores de `Procedencia` al atributo `shape` (forma):

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso, shape = Procedencia) +
  geom_point() +
  geom_line(stat = 'smooth', method = 'lm')
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory
```

```
Warning: Removed 300 rows containing missing values (`geom_point()`).
```

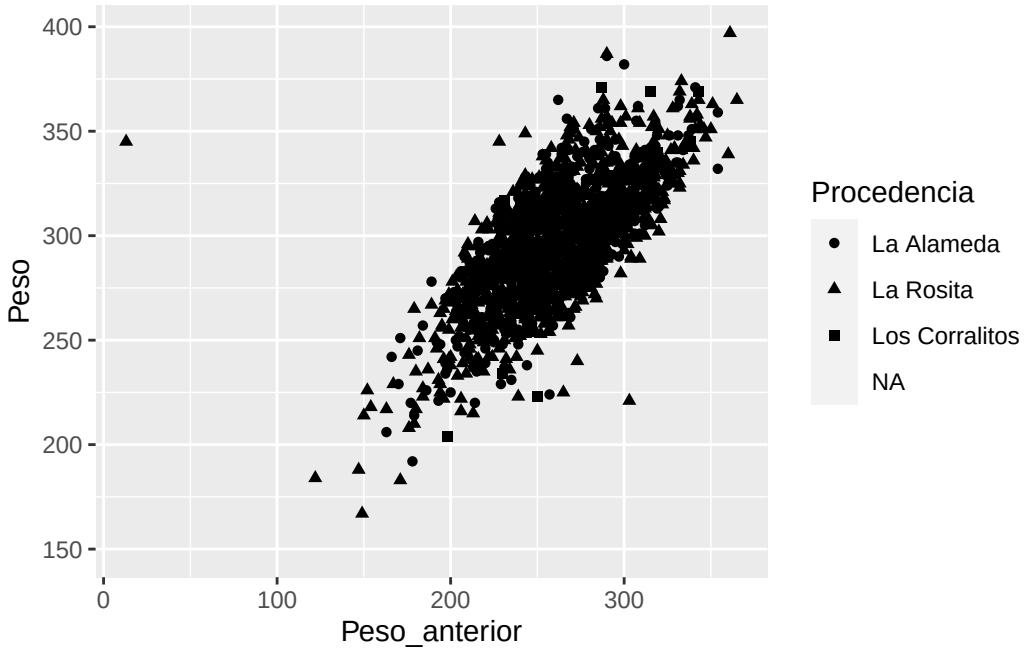

Las estéticas se pueden combinar para mostrar mas relaciones entre variables. Por ejemplo, además de `shape = Procedencia` podríamos agregar la información de los pesos iniciales como color:

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso, shape = Procedencia,
      color = Peso_inicial) +
  geom_point() +
  geom_line(aes(group = Procedencia), stat = "smooth", method = "lm")
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory
```

```
Warning: Removed 300 rows containing missing values (`geom_point()`).
```

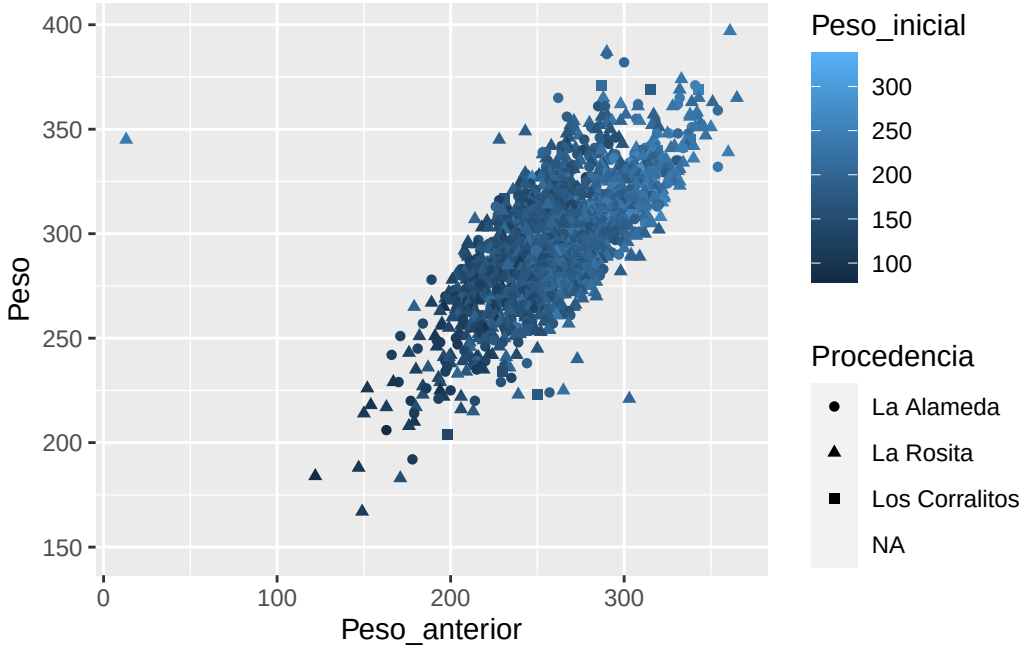

Claramente esto es una exageración pero muestra la potencialiadad de `ggplot2`. Siempre tener en cuenta balance entre simplicidad del gráfico y la cantidad de información que queremos comunicar.

Finalmente vamos a ver como mejorar los nombres de los ejes, leyendas y agregar un título. Esto lo hacemos con `labs()`. Tambien agregamos algun tema predefinido ocomo `theme_bw()`.

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso, color = Procedencia) +
  geom_point() +
  geom_line(stat = "smooth", method = "lm") +
  labs(x = "Peso anterior (kg)", y = "Peso actual (kg)",
       color = "Procedencia", title = "Relación peso anterior y actual") +
  theme_bw()
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory

Warning: Removed 32 rows containing missing values (`geom_point()`).
```

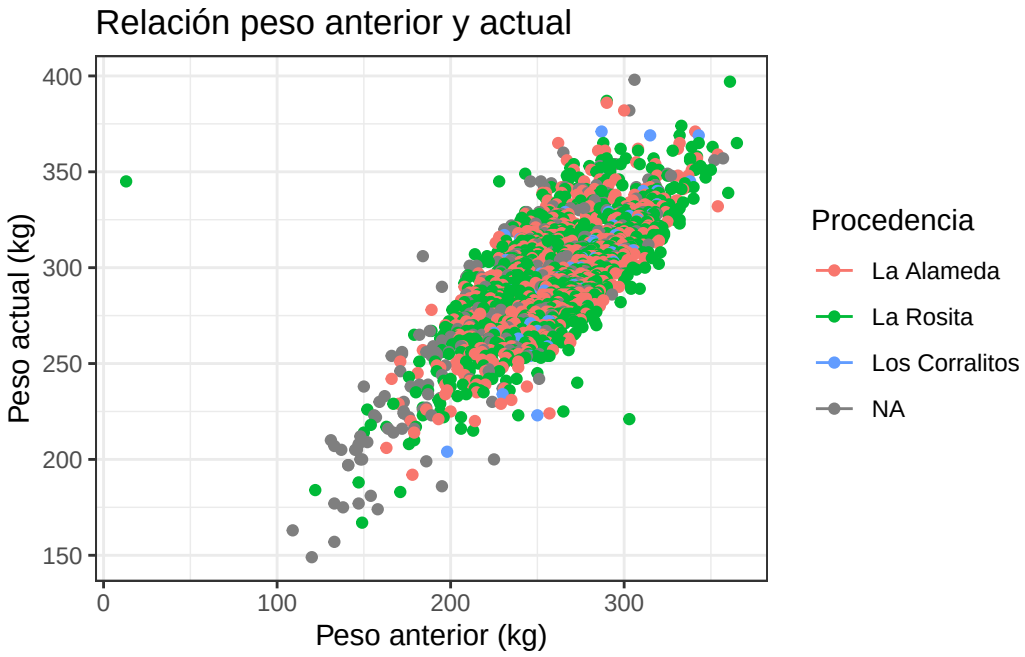

7.4 Gráficos condicionales o por paneles: `facets`

A veces es util mostrar los subgrupos en gráficos individuales o paneles. Esto se hace facilmente usando una o más variables condicionales con `facets`. Este tipo de gráficos también se denomian graficos condicionales ya que muestran la relacion de al menos dos variables de interés a través de los niveles de una tercera variable: `y ~ x | z`.

Por ejemplo, en el primer gráfico vimos como mostrar la relación entre los pesos y las procedencias como color. Eventualmente, ese gráfico podria dividirse en 4 paneles (uno por procedencia) y mostrar en cada uno el subconjunto de puntos.

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso) +
  geom_point() +
```

```
    geom_line(stat = 'smooth', method = 'lm') +
    facet_wrap(~ Procedencia)
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory
```

```
Warning: Removed 32 rows containing missing values (`geom_point()`).
```

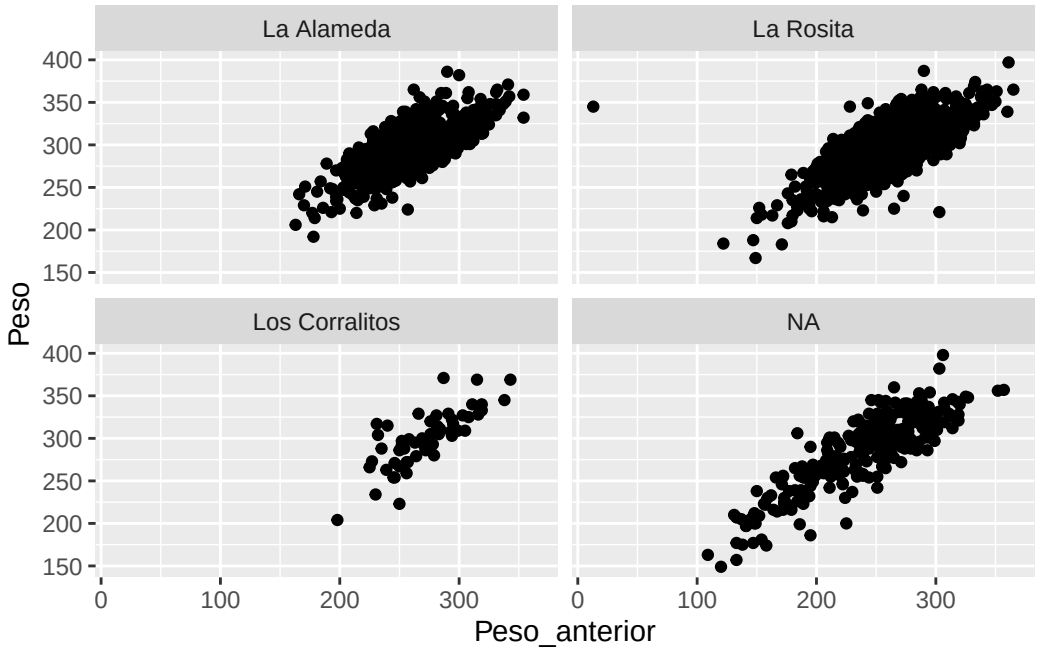

Hay dos tipos de facetado: `facet_wrap()` y `facet_grid()`. El primero permite agregar una o mas variables condicionales pero cada subpanel se muestra secuencialmente. Funciona bien

cuando tenemos una sola variable para dividir los subplots o pocos niveles en la combinación. La forma de indicar la variable es `~ variable`.

En cambio, `facet_grid()` permite organizar los subplots en filas y columnas. Las varialbes se indican en este orden `fila ~ columna`. Para este ejemplo vamos a usar la variable `Tropa`:

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso) +
  geom_point() +
  geom_line(stat = 'smooth', method = 'lm') +
  facet_grid(Tropa ~ Procedencia)
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory
```

```
Warning: Removed 32 rows containing missing values (`geom_point()`).
```

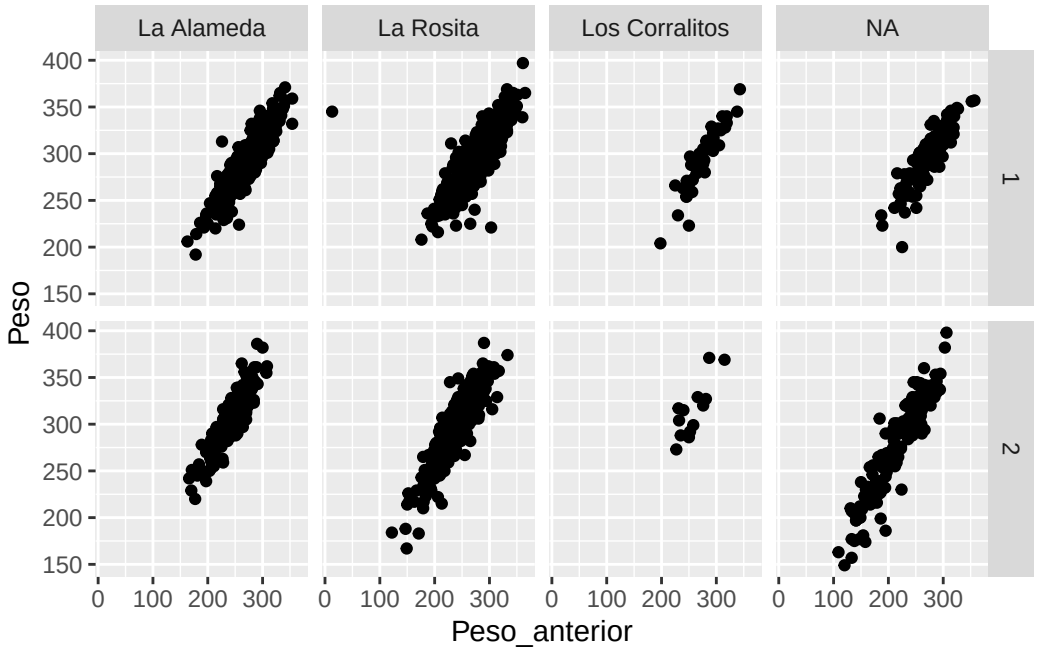

Por defecto los subplots o `facets` tienen escalas iguales en ambos ejes para comparar. A veces conviene dejar una o las dos escalas variar libremente, esto se hace con el argumento `scales` y las palabras clave `'free_y'`, `'free_x'` o `'free'` (ambas a la vez).

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso) +
  geom_point() +
  geom_line(stat = 'smooth', method = 'lm') +
  facet_grid(Tropa ~ Procedencia, scales = "free")
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
```

```
Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory

Warning: Removed 32 rows containing missing values (`geom_point()`).
```

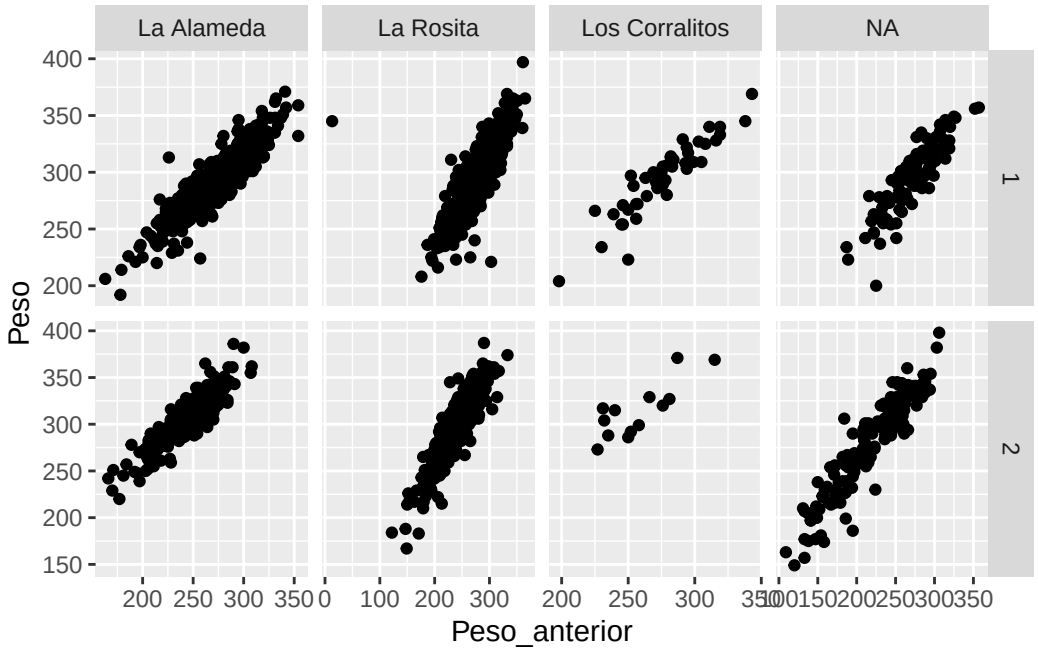

Otra aspecto importante en la visualización usando facets es el texto que identifica cada panales. Esto depende de como estan configurados los datos y se controla con el argument `labeller`. Por defecto se toma el valor del factor que se usa para definir los grupos. En algunos casos conviene incluir el nombres de la variable.

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso) +
  geom_point() +
  geom_line(stat = 'smooth', method = 'lm') +
  facet_grid(Tropa ~ Procedencia, scales = "free", labeller = label_both)
```

```
`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory

Warning: Removed 32 rows containing missing values (`geom_point()`).
```

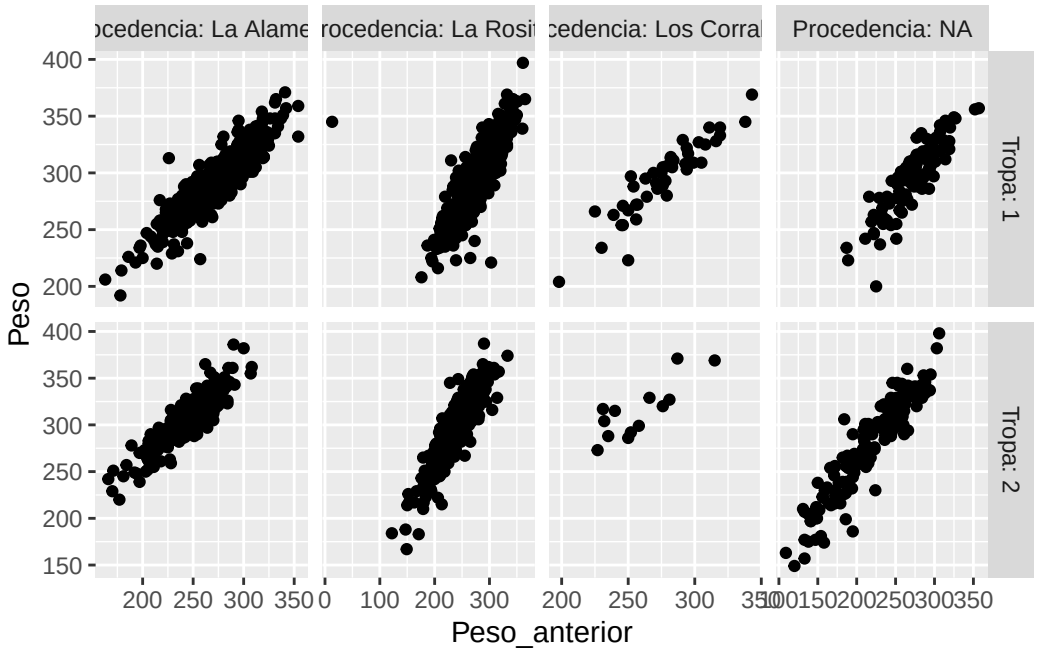

7.5 Temas

Los temas en `ggplot` hacen referencia al control fino de la posición, el aspecto, y las formas de los distintos componentes del gráfico. El listado de componentes que se pueden modificar en un tema se incluyen en `?theme()`. Como vemos la lista es larga ya que cada aspecto del gráfico puede controlarse permitiendo crear nuestros propios temas.

`ggplot2` algunos temas predefinidos. Por defecto los gráficos utilizan un tema llamado `theme_gray()` que tiene una seleccion de parámetros elegante y que sirve para la mayoría de los casos. Existen otros temas específicos que puden ser un punto de partida para hacer modificaciones extra.

Por ejemplo, el tema `them_bw()` remueve el fondo gris pero si queremos quitar la grilla podemos hacer:

```
# Modificar el tema
mi_tema <- theme_bw() + theme(panel.grid = element_blank())

# Aplicar nuestro nuevo tema.
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso, color = Procedencia) +
  geom_point() +
  geom_line(stat = 'smooth', method = 'lm') +
  mi_tema
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory
```

```
Warning: Removed 32 rows containing missing values (`geom_point()`).
```

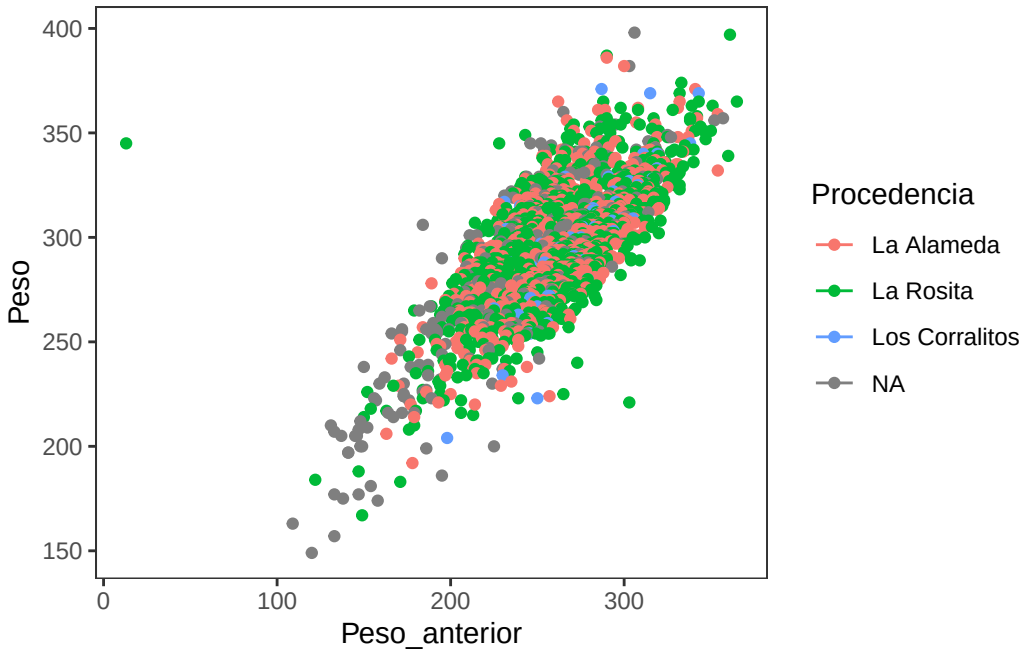
400
350
300
250
200
150
Peso
0
100
200
300
Peso_anterior
Procedencia
La Alameda
La Rosita
Los Corralitos
NA

8 Reportes dinámicoas

R tiene por defecto el paquete `graphics`, también conocido como *base plot system*, que provee la función genérica `plot()` para hacer gráficos simples, y otras funciones para gráficos específicos (`hist()`, `barplot()`, `boxplot()`, etc).

Usa un enfoque de *papel y lapiz* por capas donde el gráfico final es una sumatoria de capas que se agregan una a la vez sin posibilidad de modificarse luego. Generalmente es OK para gráficos simples o exploratorios. Para gráficos más complejos (con subgrupos o multipanel) requiere programar más. Una desventaja es la sintaxis poco consistente.

El paquete `ggplot2`, desarrollado por Hadley Wickham, está basado en la filosofía *Gramática de gráficos* (*grammar of graphics* , por eso `gg`). Combina los dos enfoques: *por capas* y *función*.

Uno provee los datos, indica que variables asignar a las estéticas (ejes, escalas, colores, símbolos) y las geometrías o formas que se quieren graficar y `ggplot2` se encarga del resto. Se puede ir agregando capas. Es muy potente para la exploración y visualización de datos en formato de tabla con filas (observaciones) y columnas (variables).

8.1 ¿Cómo conseguir `ggplot2`?

Para acceder a estos paquetes instalarlos/cargarlos individualmente:

```
pacman::p_load(ggplot2)
```

O bien con otros paquete de la familia `tidyverse`

```
pacman::p_load(tidyverse)
```

R va a avisarnos en la consola que esta enmascarando (reemplazando) algunas funciones que ya estaban en el entorno, o bien el paquete nos devuelve algun mensaje. A menos que diga `Error ...`, eso está bien.

8.2 Componentes del gráfico en `ggplot2`

`ggplot2` implementa una variante *por capas* de este paradigma gramática de gráficos de Leland Wilkinson (`gg` es por *grammar of graphics*). Como resultado, se crean una serie de capas que permiten describir y construir visualizaciones de manera estructurada en cuanto a representación de los elementos pero a su vez flexible para generar combinaciones nuevas.

Un gráfico se define por la combinación de capas (`layers`), escalas (`scales`), coordenadas (`coords`) y facetas (`facets`). Adicionalmente a estos componentes se pueden aplicar temas (`themes`) que permiten controlar los detalles del diseño de la visualización.

8.2.1 Layers

Los `layer` se construyen con las funciones `geom_*` y `stat_*` que veremos más adelante. Constan de 5 elementos:

- `data`, set de datos (`data.frame` o similar) que contiene la información que se desea visualizar.
- `mapping`, elementos de mapeo definidos mediante `aes()` para indicar la forma en que la las variables y observaciones van a ser representadas en la visualización mediante atributos estéticos (ejes, lineas, colores, rellenos, etc).
- `stat`, funciones estadísticas que resumen los datos aplicando funciones estadísticas, e.g. promedio, agrupamiento y conteo de observaciones, o ajuste de un modelo lineal o suavizado, etc.
- `geom`, geometrías o formas que representan lo que realmente se ve en un gráfico: puntos, líneas, polígonos, etc.
- `position`, ajuste de posición de los elementos `geoms` dentro de un layer para evitar su superposición.

Generalmente, sobre todo para gráficos simples, `data` y `mapping` se definen una vez para todo el gráfico dentro de la función `ggplot()`. En otras situaciones se hace a nivel de cada `layer`.

8.2.2 Scales

Asignan los valores del espacio de datos a valores en el espacio de los elementos estéticos (`aesthetics` o `aes`). Por ejemplo, el uso de un color, forma o tamaño de en un `geom` puede ser controlado por un atributo de los datos. Las escalas también definen las leyenda y los ejes.

8.2.3 Coordenadas

Sistema de coordendas (`coord`) que define que variables definiran el espacio del gráfico y como se representarán, e.g. coordanedas cartesianas, polares, etc.

8.2.4 Paneles (`facets`)

Es un elemento que permite especificar una o más variables para dividir el gráfico en paneles y así mostrar subgrupos de datos. Esto permite ver visualizar relaciones condicionales entre variables, e.g. `y ~ x | z`, es decir, que pasa con la variable `x` e `y` cuando cambia `z`.

8.2.5 Temas

Adicionalmente a estos componentes se pueden aplicar temas (`themes`) que permiten controlar los detalles del desieño de la visualización, tipografía, posición de algunos objetos, paleta de colores, etc. Los valores predeterminados de `ggplot2` son un buen punto de partida pero exiten opciones predefinidas que pueden modificarse para generar un tema particular. Otra fuente para consultar es el trabajo de Tufte

8.3 Primer gráfico paso a paso

```
pacman::p_load(rio)
novillos <- import("datasets/pesada_novillos.xlsx", setclass = "tibble")
novillos
```

```
# A tibble: 1,842 x 13
   IDV   Tropa Procedencia Fecha_Ingreso Peso_inicial Peso_anterior GPV_anterior
   <chr> <dbl> <chr>       <chr>                <dbl>         <dbl>        <dbl>
 1 GH73~     2 <NA>        42939                  188           306           51
 2 IA67~     2 La Rosita   42940                  232           290            2
 3 PO15~     2 La Alameda  42939                  204           290           33
 4 GH73~     2 <NA>        42940                  204           303           27
 5 SZ20~     2 La Alameda  42940                  202           300           30
 6 IA67~     2 La Rosita   42940                  234           333           38
 7 PO15~     2 Los Corral~ 42938                  214           287           14
 8 PO15~     2 Los Corral~ 42939                  184           315           37
 9 NS50~     2 La Rosita   42938                  234           288            0
10 QX67~     2 La Alameda  42940                  206           262            2
# i 1,832 more rows
```

```
# i 6 more variables: GDM_anterior <dbl>, Fecha <chr>, Hora <chr>, Peso <dbl>,
#   Días <dbl>, Días_total <dbl>
```

Veamos con un ejemplo como se combinan los componentes anteriormente vistos para realizar un gráfico simple. Para esto vamos a usar el set de datos

Nuestro primer gráfico tendrá como objetivo mostrar la relación que existe entre `Peso_anterior` y `Peso` (actual), y potencialmente ver si ésta es similar entre procedencias. Veamos paso por paso como se construye el gráfico.

Primero definimos el set de datos que usaremos:

```
ggplot(data = novillos)
```


Como vemos esto no produjo nada ya que no indicamos cuales son las variables que queremos graficar y cómo graficarlas. Nuestro `layer` solo tiene la información de `data`. Agreguemos ahora la información de `mappping` usando `aes()`. Usando el operador `+` podemos concatenarlo al comando anterior.

```
ggplot(data = novillos) +
  aes(x = Peso_inicial, y = Peso)
```

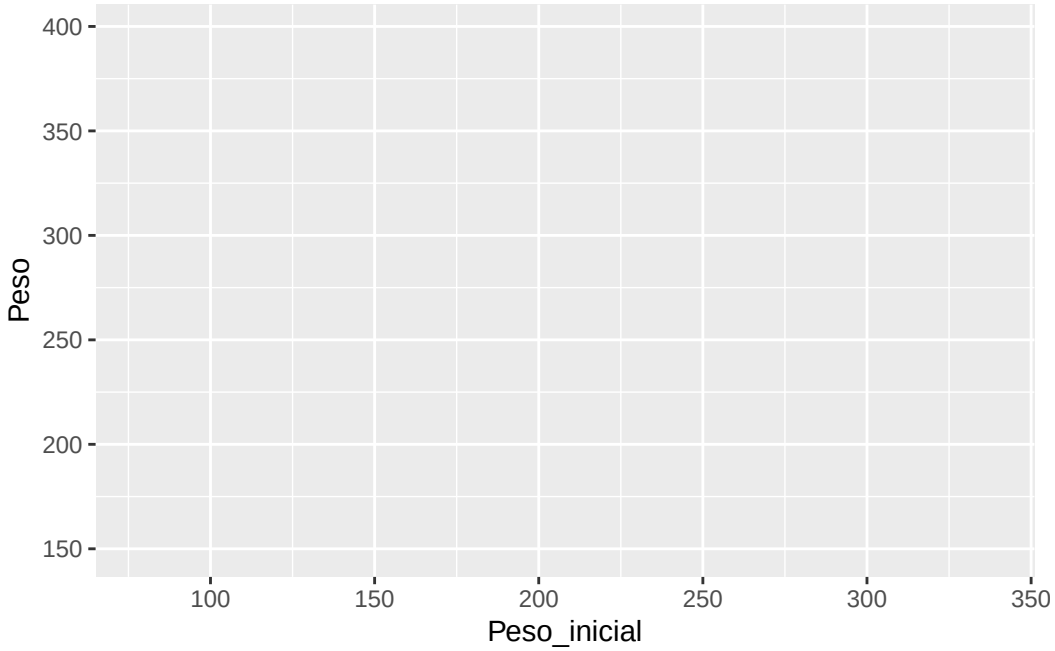

Aquí vemos que, si bien no hemos graficado nada, la información suministrada permite a `ggplot` identificar los ejes, definir el espacio de coordanadas (cartesianas por defecto) y proponer unos límites en función del rango de valores. Agreguemos ahora la geometría: en este caso tiene sentido usar `geom_point()` ya que queremos mostrar un punto por observación

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso) +
  geom_point()
```

```
Warning: Removed 32 rows containing missing values (`geom_point()`).
```

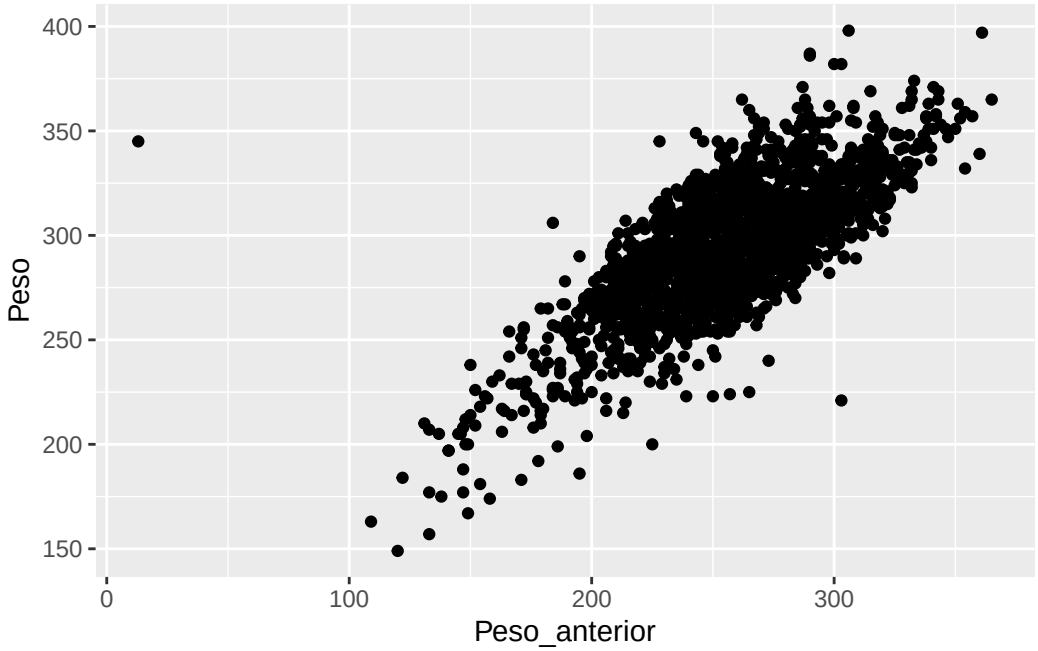

Como vemos ahora el gráfico va tomando forma. Este tipo de gráficos se llama *gráfico de dispersión* y muestra la relación entre ambas variables. Por defecto no se aplica ninguna transformación estadística lo que equivale a (`stat = "identity"`).

A este gráfico vamos a agregarle alguna función que permita resumir la relación entre ambas variables, por ejemplo un modelo de regresión. La mejor forma de representarlo sería una línea. Para eso vamos a agregar otro `layer` con `geom_line()` donde indicaremos una transformación de los datos `stat = smooth`.

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso) +
  geom_point() +
  geom_line(stat = 'smooth', method = 'lm')
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory
```

```
Warning: Removed 32 rows containing missing values (`geom_point()`).
```

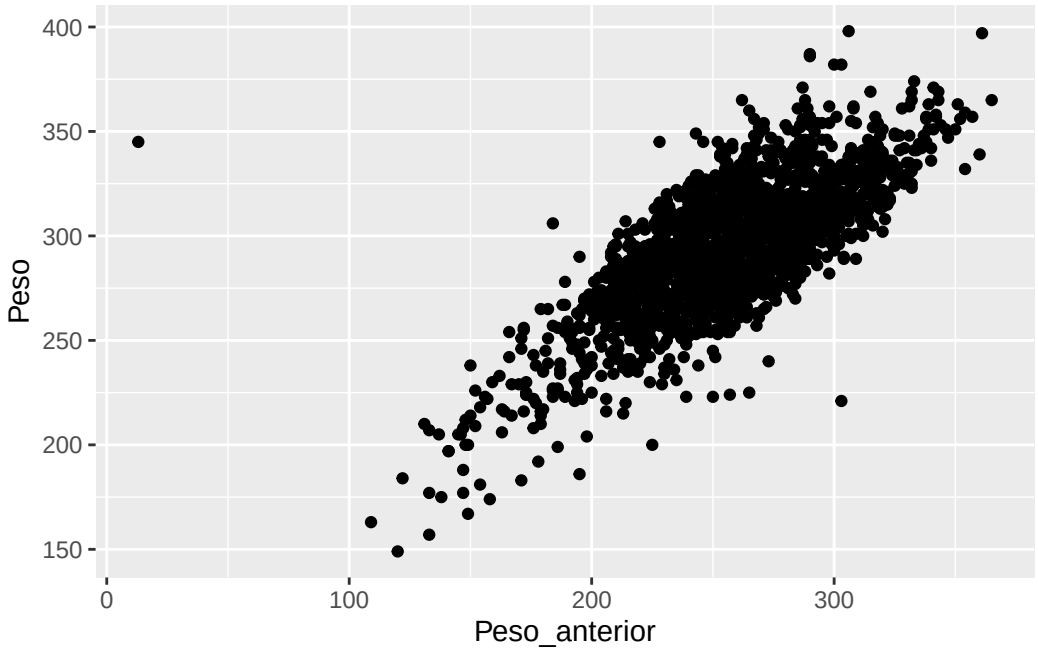

Hay una relación positiva para todo el set de datos pero puede enmascarar algun patrón por `Procedencia`. Esta información la podemos agregar con otros atributos estéticos como por ejemplo `color`:

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso, color = Procedencia) +
  geom_point() +
  geom_line(stat = 'smooth', method = 'lm')
```

```
`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).

Warning: Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory

Warning: Removed 32 rows containing missing values (`geom_point()`).
```

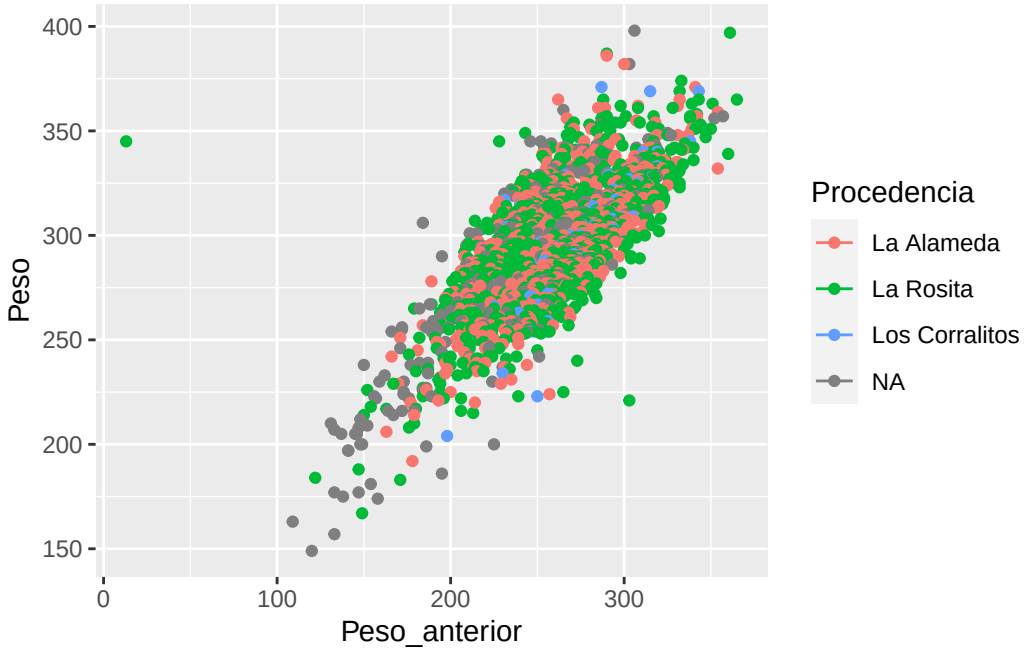

De este gráfico surge que la relación en todos los casos es positiva pero varia un poco según procedencia.

Dependiendo el tipo de `geom` tenemos distintos atributos estéticos para explorar: `color` y `alpha` (transparencia) para todos, `shape` y `size` para puntos, `linewidth` y `linetype` para lineas, y `fill` para barras, etc. Que tipo de atributo estético depende también de la naturaleza de la variable: continua o discreta. Veamos como queda mapear los valores de `Procedencia` al atributo `shape` (forma):

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso, shape = Procedencia) +
  geom_point() +
  geom_line(stat = 'smooth', method = 'lm')
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory
```

```
Warning: Removed 300 rows containing missing values (`geom_point()`).
```

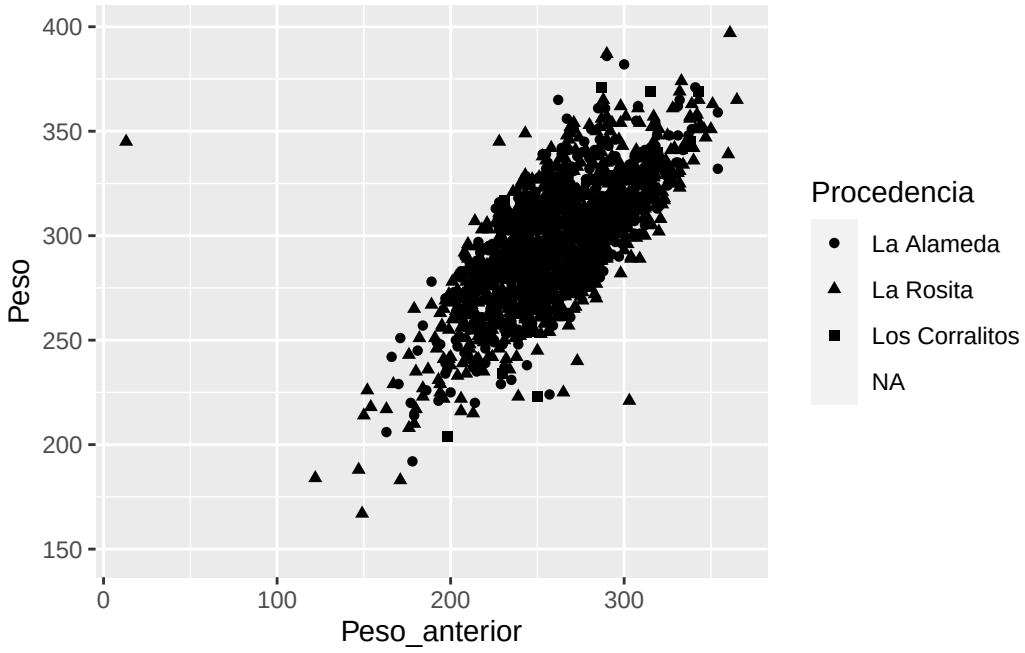

Las estéticas se pueden combinar para mostrar mas relaciones entre variables. Por ejemplo, además de `shape = Procedencia` podríamos agregar la información de los pesos iniciales como color:

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso, shape = Procedencia,
      color = Peso_inicial) +
  geom_point() +
  geom_line(aes(group = Procedencia), stat = "smooth", method = "lm")
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory
```

```
Warning: Removed 300 rows containing missing values (`geom_point()`).
```

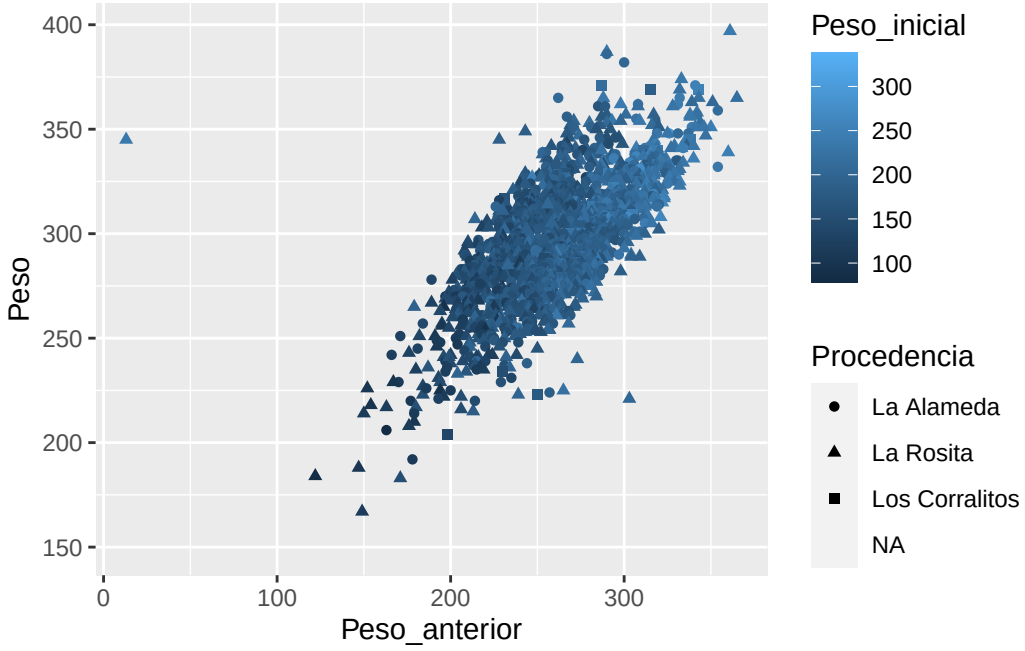

Claramente esto es una exageración pero muestra la potencialiadad de `ggplot2`. Siempre tener en cuenta balance entre simplicidad del gráfico y la cantidad de información que queremos comunicar.

Finalmente vamos a ver como mejorar los nombres de los ejes, leyendas y agregar un título. Esto lo hacemos con `labs()`. Tambien agregamos algun tema predefinido ocomo `theme_bw()`.

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso, color = Procedencia) +
  geom_point() +
  geom_line(stat = "smooth", method = "lm") +
  labs(x = "Peso anterior (kg)", y = "Peso actual (kg)",
       color = "Procedencia", title = "Relación peso anterior y actual") +
  theme_bw()
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory

Warning: Removed 32 rows containing missing values (`geom_point()`).
```

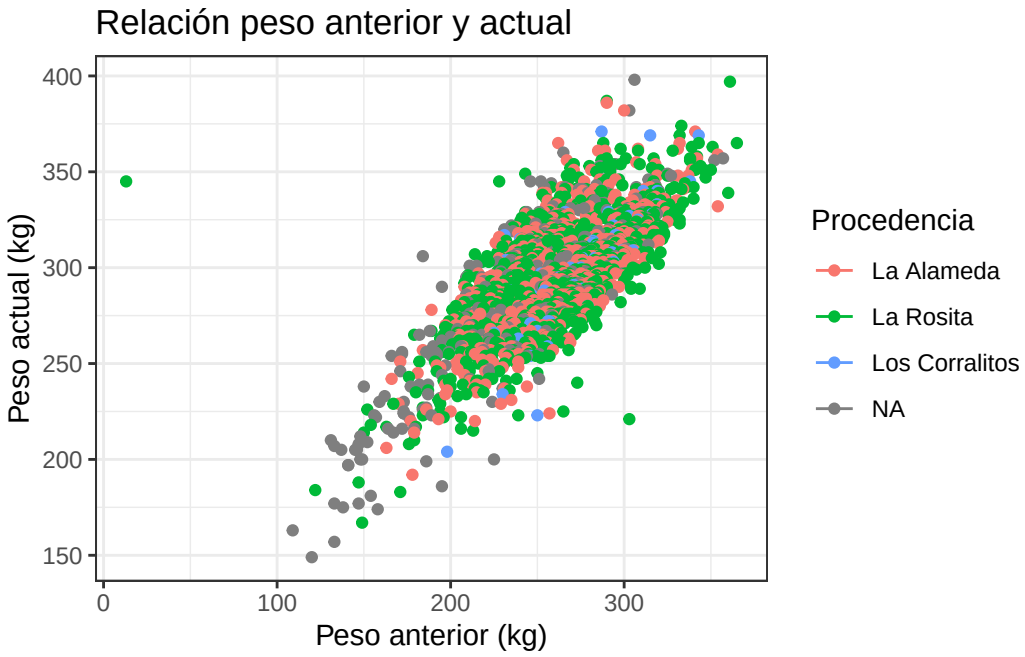

8.4 Gráficos condicionales o por paneles: `facets`

A veces es util mostrar los subgrupos en gráficos individuales o paneles. Esto se hace facilmente usando una o más variables condicionales con `facets`. Este tipo de gráficos también se denomian graficos condicionales ya que muestran la relacion de al menos dos variables de interés a través de los niveles de una tercera variable: `y ~ x | z`.

Por ejemplo, en el primer gráfico vimos como mostrar la relación entre los pesos y las procedencias como color. Eventualmente, ese gráfico podria dividirse en 4 paneles (uno por procedencia) y mostrar en cada uno el subconjunto de puntos.

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso) +
  geom_point() +
```

```
    geom_line(stat = 'smooth', method = 'lm') +
    facet_wrap(~ Procedencia)
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory
```

```
Warning: Removed 32 rows containing missing values (`geom_point()`).
```

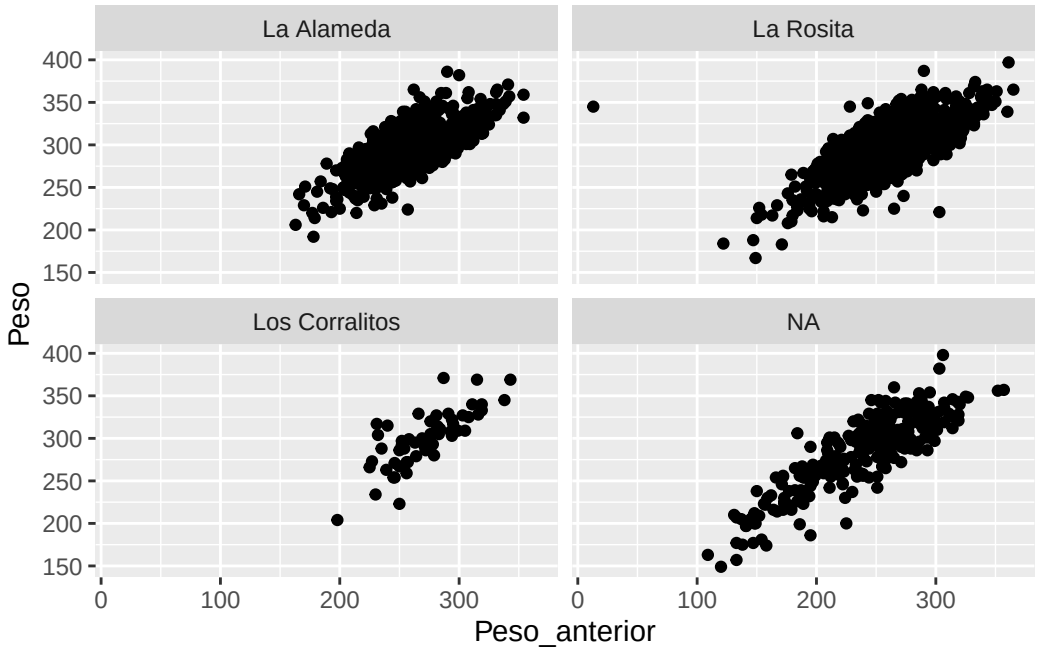

Hay dos tipos de facetado: `facet_wrap()` y `facet_grid()`. El primero permite agregar una o mas variables condicionales pero cada subpanel se muestra secuencialmente. Funciona bien

cuando tenemos una sola variable para dividir los subplots o pocos niveles en la combinación. La forma de indicar la variable es `~ variable`.

En cambio, `facet_grid()` permite organizar los subplots en filas y columnas. Las varialbes se indican en este orden `fila ~ columna`. Para este ejemplo vamos a usar la variable `Tropa`:

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso) +
  geom_point() +
  geom_line(stat = 'smooth', method = 'lm') +
  facet_grid(Tropa ~ Procedencia)
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory
```

```
Warning: Removed 32 rows containing missing values (`geom_point()`).
```

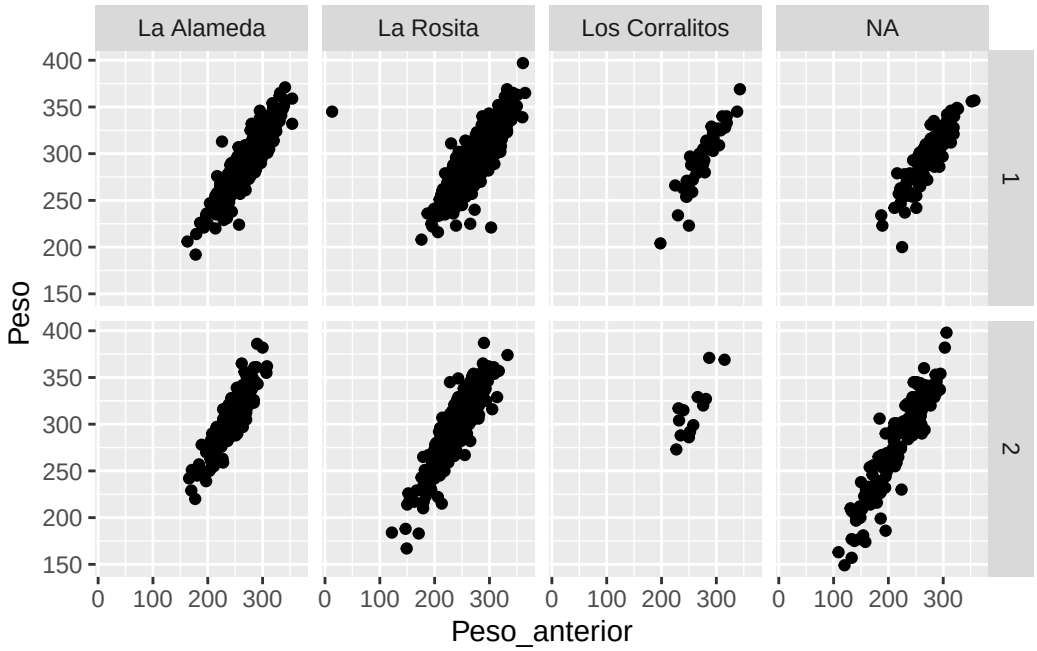

Por defecto los subplots o `facets` tienen escalas iguales en ambos ejes para comparar. A veces conviene dejar una o las dos escalas variar libremente, esto se hace con el argumento `scales` y las palabras clave `'free_y'`, `'free_x'` o `'free'` (ambas a la vez).

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso) +
  geom_point() +
  geom_line(stat = 'smooth', method = 'lm') +
  facet_grid(Tropa ~ Procedencia, scales = "free")
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
```

```
Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory

Warning: Removed 32 rows containing missing values (`geom_point()`).
```

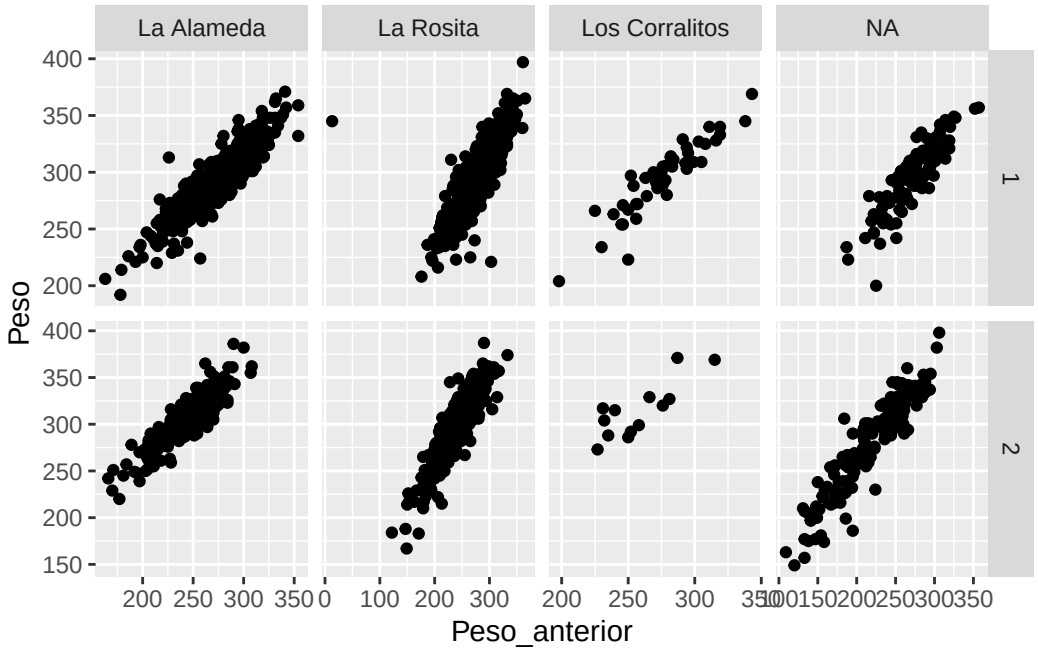

Otra aspecto importante en la visualización usando facets es el texto que identifica cada panales. Esto depende de como estan configurados los datos y se controla con el argument `labeller`. Por defecto se toma el valor del factor que se usa para definir los grupos. En algunos casos conviene incluir el nombres de la variable.

```
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso) +
  geom_point() +
  geom_line(stat = 'smooth', method = 'lm') +
  facet_grid(Tropa ~ Procedencia, scales = "free", labeller = label_both)
```

```
`geom_smooth()` using formula = 'y ~ x'

Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory

Warning: Removed 32 rows containing missing values (`geom_point()`).
```

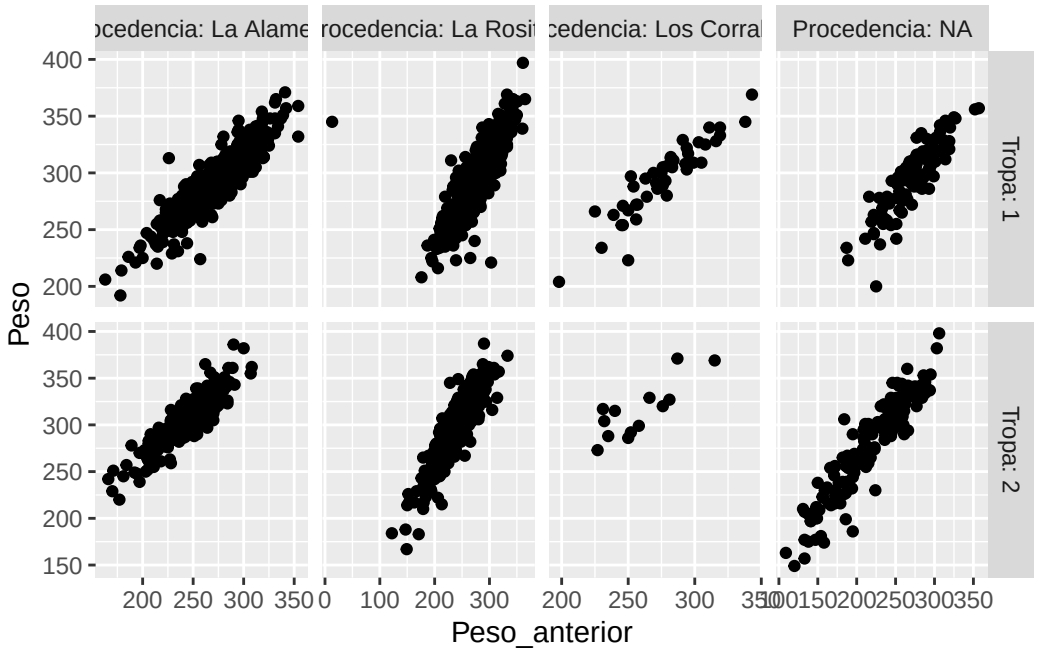

8.5 Temas

Los temas en `ggplot` hacen referencia al control fino de la posición, el aspecto, y las formas de los distintos componentes del gráfico. El listado de componentes que se pueden modificar en un tema se incluyen en `?theme()`. Como vemos la lista es larga ya que cada aspecto del gráfico puede controlarse permitiendo crear nuestros propios temas.

`ggplot2` algunos temas predefinidos. Por defecto los gráficos utilizan un tema llamado `theme_gray()` que tiene una seleccion de parámetros elegante y que sirve para la mayoría de los casos. Existen otros temas específicos que puden ser un punto de partida para hacer modificaciones extra.

Por ejemplo, el tema `them_bw()` remueve el fondo gris pero si queremos quitar la grilla podemos hacer:

```
# Modificar el tema
mi_tema <- theme_bw() + theme(panel.grid = element_blank())

# Aplicar nuestro nuevo tema.
ggplot(data = novillos) +
  aes(x = Peso_anterior, y = Peso, color = Procedencia) +
  geom_point() +
  geom_line(stat = 'smooth', method = 'lm') +
  mi_tema
```

```
`geom_smooth()` using formula = 'y ~ x'
```

```
Warning: Removed 32 rows containing non-finite values (`stat_smooth()`).
```

```
Warning: Computation failed in `stat_smooth()`
Caused by error in `dyn.load()`:
! unable to load shared object '/usr/lib/R/library/Matrix/libs/Matrix.so':
  libopenblas.so.3: cannot open shared object file: No such file or directory
```

```
Warning: Removed 32 rows containing missing values (`geom_point()`).
```

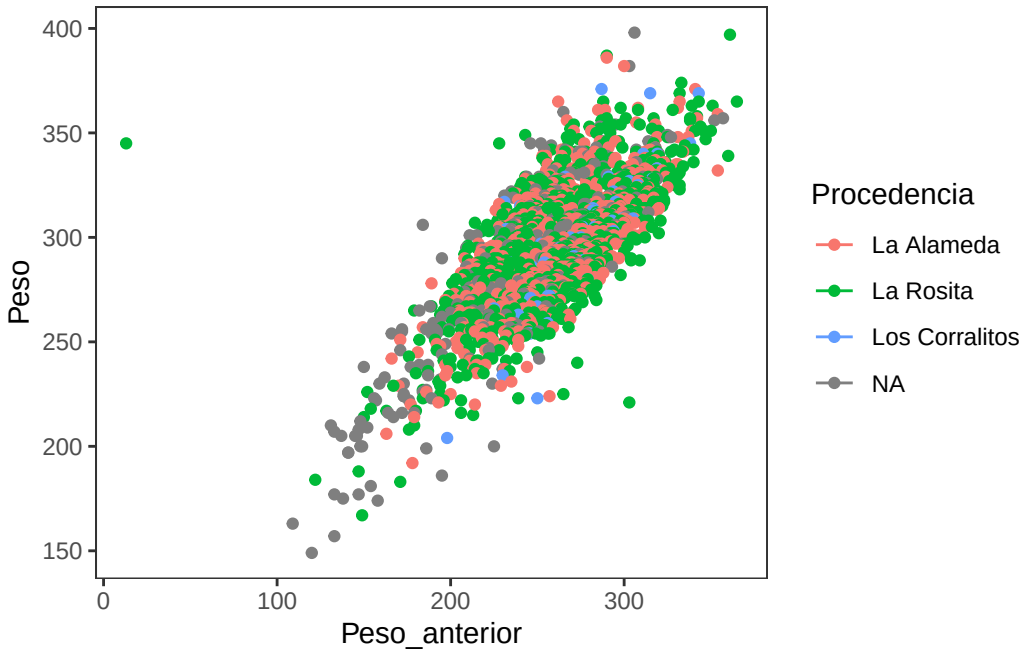
400
350
300
250
200
150
Peso
0
100
200
300
Peso_anterior
Procedencia
La Alameda
La Rosita
Los Corralitos
NA

References

R Core Team. 2023. *R: A Language and Environment for Statistical Computing*. Vienna, Austria: R Foundation for Statistical Computing. https://www.R-project.org/.